

CPJ-Cobrança AI

Manual Técnico & Documentação de Arquitetura

Desafio Técnico Dev Pleno

Solução de Agente de IA para Apoio de Processo de Desenvolvimento

Autor: Cledson Santos

Data: Maio de 2026

Versão: 1.0.0

Introducao

Objetivo deste capitulo

Este capitulo apresenta o projeto desenvolvido para o case tecnico CPJ-Cobrança AI em nivel executivo e tecnico. A ideia e deixar claro, desde o inicio, que esta documentacao faz parte da entrega do case: ela explica o contexto do desafio, a proposta da solucao, o que foi construido e por que as decisoes tecnicas foram tomadas.

O objetivo e permitir que um avaliador entenda rapidamente qual problema foi resolvido, qual solucao foi entregue, quais diferenciais tecnicos existem e por onde continuar a leitura.

Esta introducao nao tenta explicar todos os detalhes internos. Arquitetura, contratos de API, persistencia, deploy, testes e extensibilidade serao detalhados nos proximos capitulos.

Contexto do case

O projeto nasceu como resposta a um case tecnico com foco em cobranca, automacao e uso pratico de IA no ciclo de desenvolvimento. Em vez de entregar apenas um prototipo pontual, a proposta foi construir uma base de produto avaliavel: API, persistencia, agentes, painel web, documentacao interativa, Docker, testes e caminhos claros de evolucao.

Nesse contexto, o CPJ-Cobrança AI e uma solucao para apoiar atividades tecnicas relacionadas a analise de codigo, aderencia a requisitos, documentacao, geracao de testes e revisao de Pull Requests com auxilio de agentes de IA.

O nome do projeto reflete o objetivo do case: criar uma ferramenta aplicavel ao ambiente CPJ-Cobrança, onde revisoes, documentacao, verificacao de regras e qualidade tecnica podem ser aceleradas por fluxos automatizados, mas ainda mantendo rastreabilidade para avaliacao humana.

Em vez de tratar a IA como uma chamada isolada de chat, o projeto organiza cada capacidade em fluxos especializados. Esses fluxos combinam validacao de contratos, ferramentas deterministicas, prompts versionados, modelos configuraveis, grafos LangGraph, persistencia de historico, telemetria e uma interface web para acompanhamento operacional.

O resultado e uma API pronta para avaliacao tecnica, acompanhada por um painel administrativo Next.js e por uma estrutura de execucao local ou containerizada.

O que o case pedia

O enunciado do case solicitava a construção de um microserviço backend containerizado, com API REST, capaz de expor um agente de IA para automatizar quatro fluxos do processo de desenvolvimento do CPJ-Cobrança.

Os quatro fluxos obrigatórios eram:

- **Code Review Automatizado:** endpoint `POST /api/v1/review`, recebendo um trecho de código, linguagem e contexto opcional, e retornando qualidade geral, nota, problemas encontrados, pontos positivos e resumo.
- **Avaliação de Aderência a Tarefa:** endpoint `POST /api/v1/compliance`, cruzando uma descrição de tarefa com o código implementado para apontar requisitos atendidos, ausentes e parcialmente atendidos.
- **Geração de Documentação Técnica:** endpoint `POST /api/v1/document`, gerando documentação técnica ou operacional a partir de código informado.
- **Geração de Testes Unitários:** endpoint `POST /api/v1/tests`, produzindo casos de teste, dicas de cobertura e o conteúdo completo de um arquivo de teste.

Também eram obrigatórios endpoints auxiliares para operação e rastreabilidade:

- `GET /health`, para healthcheck da aplicação;
- `GET /api/v1/history`, para listar as últimas execuções;
- `GET /api/v1/history/{id}`, para consultar o resultado completo de uma execução específica.

Do ponto de vista técnico, o case exigia:

- persistência das execuções do agente em banco de dados;
- integração com algum provedor LLM, documentando modelo, configuração e custo estimado quando aplicável;
- Dockerfile, `docker-compose.yml` e `.env.example`;
- subida da aplicação com `docker compose up --build`;
- documentação clara de setup, variáveis de ambiente e exemplos funcionais;
- repositório público com código-fonte, configuração Docker e coleção de exemplos via Postman, Insomnia ou arquivo `.http`.

O README também era parte central da entrega. O enunciado pedia que ele explicasse decisões técnicas, instruções de execução com Docker, configuração de ambiente, exemplos completos de request e response para cada fluxo, diferenciais implementados e o que seria feito com mais tempo.

Critérios de avaliação do case

O case definia avaliação de 1 a 5 em cada critério, com pesos diferentes:

Critério	Peso	O que era avaliado
Funcionalidade	25%	Quatro fluxos funcionando, Docker subindo e endpoints respondendo corretamente.
Qualidade do agente / IA	25%	Qualidade dos prompts, utilidade real das saídas e tratamento de falhas do LLM.
Qualidade do código	20%	Organização, legibilidade, separação de responsabilidades e consistência.
README e documentação	15%	Clareza, decisões justificadas e exemplos que realmente funcionam.
Persistência e modelagem	10%	Schema adequado, queries corretas e dados consistentes.
Diferenciais implementados	5%	Qualidade e utilidade dos itens extras escolhidos.

O enunciado deixava claro que uma solução simples, legível e funcional teria mais valor do que uma arquitetura sofisticada que não subisse ou que não tivesse instruções de uso confiáveis.

Também valorizava a forma de pensar, documentar, comunicar trade-offs e construir algo realista com IA.

Entre os diferenciais sugeridos estavam LangGraph ou LangChain, prompt templating estruturado, cache por hash, logs estruturados, tracing com LangSmith, batch, streaming via Server-Sent Events, webhook callback, testes automatizados e validação de schema na entrada e na saída.

Problema resolvido

Atividades como revisar código, verificar se uma entrega atende uma tarefa, gerar documentação ou sugerir testes costumam depender de leitura manual, critérios pouco padronizados e conhecimento disperso entre pessoas do time.

O projeto resolve esse problema criando uma camada automatizada e rastreável para apoiar essas decisões. A API recebe código, contexto ou dados de Pull Request, executa um fluxo especializado e devolve uma resposta estruturada que pode ser armazenada, revisada, auditada e comparada depois.

Essa abordagem ajuda em quatro pontos principais:

- padronizar análises técnicas com contratos previsíveis;
- reduzir trabalho repetitivo de revisão, documentação e testes;
- registrar histórico, steps, modelo usado, tokens e custos;
- permitir evolução controlada de prompts, modelos e agentes.

Visão geral da solução

A solução é composta por duas partes principais:

- **API backend:** aplicação Node.js com TypeScript e Fastify, responsável por expor endpoints HTTP, validar payloads, executar fluxos de IA, persistir histórico e disponibilizar documentação OpenAPI.
- **Painel web admin:** aplicação Next.js em [apps/web](#), usada para acompanhar histórico, prompts, modelos, status da API, custos, tokens e execução guiada dos fluxos.

O backend usa PostgreSQL via Prisma para persistir execuções, steps, telemetria, prompts versionados, catálogo de modelos e resumos de batch. Os fluxos de IA usam LangGraph.js e LangChain.js com OpenRouter como provedor LLM. LangSmith pode ser ativado opcionalmente para tracing.

Capacidades entregues

O projeto entrega os seguintes fluxos e recursos:

- **review**: revisão de código multi-linguagem para TypeScript, JavaScript, Python e PHP.
- **review/stream**: revisão de código com Server-Sent Events para acompanhar a execução em tempo real.
- **review/pull-request**: revisão de Pull Request no GitHub, com padrões de código, segurança, consistência de projeto e critérios Jira opcionais.
- **compliance**: avaliação de aderência entre descrição da tarefa e código implementado.
- **document**: geração de documentação técnica ou operacional a partir de código.
- **tests**: geração de estratégia, casos e arquivo de testes.
- **tests/pull-request**: geração de testes unitários baseada nas funções e trechos críticos alterados em um Pull Request.
- **batch**: execução sequencial de múltiplos fluxos em uma única requisição.
- **history**: consulta das execuções persistidas, incluindo detalhes e steps.
- **analytics**: visão agregada de uso, tokens e custos.
- **prompts**: cadastro, consulta e ativação de versões de prompt por fluxo.
- **models**: cadastro, ativação e seleção de modelo padrão global.
- **webhook**: callback opcional ao finalizar fluxos principais.
- **OpenAPI/Swagger**: documentação interativa em `/docs`.

Como a solução funciona em alto nível

O fluxo padrão segue esta sequência conceitual:



```
graph LR;
  Cliente["Cliente HTTP ou painel web"]
```

```
API["API Fastify"]
Contratos["Validação Zod"]
Service["Service do fluxo"]
Engine["Engine de IA"]
Graph["Grafo LangGraph"]
LLM["OpenRouter / LLM"]
DB["PostgreSQL / Prisma"]
Resposta["Resposta estruturada"]

Cliente --> API
API --> Contratos
Contratos --> Service
Service --> Engine
Engine --> Graph
Graph --> LLM
Engine --> DB
DB --> Service
Service --> Resposta
```

Em termos práticos, uma request entra pela API, e validada pelos contratos compartilhados, passa pelo service do modulo correspondente e chega ao engine do fluxo. O engine resolve prompt e modelo, verifica cache quando aplicavel, executa o grafo LangGraph, persiste o resultado, registra telemetria e retorna um JSON estruturado.

Principais diferenciais tecnicos

O case vai alem de um endpoint simples chamando um modelo de linguagem. Os principais diferenciais sao:

- **Arquitetura modular:** cada fluxo possui controllers, routes, services, engines, graphs, agents, prompts e tools separados por responsabilidade.
- **Contratos estruturados:** entradas e saidas usam schemas compartilhados, reduzindo ambiguidade entre API, agentes, testes e painel web.
- **Grafos de agentes:** LangGraph organiza etapas observaveis, incluindo roteamento por linguagem, tools deterministicas, agentes especialistas e agregacao.
- **Persistencia completa:** historico, steps, telemetria, custos, tokens, cache e batch ficam registrados em PostgreSQL.
- **Governanca de IA:** prompts e modelos nao ficam apenas hardcoded; podem ser versionados, ativados e sobrescritos por request.
- **Operacao local e containerizada:** Docker Compose sobe API, banco e painel web, aplicando migrations e seed antes do start da API.

- **Avaliabilidade:** a solucao tem testes automatizados, OpenAPI, exemplos HTTP e comandos de verificacao para facilitar revisao tecnica.

Leitura rapida para avaliacao

Para avaliar o projeto rapidamente, a ordem recomendada e:

1. Ler este capitulo para entender o contexto e os diferenciais.
2. Abrir `02-escopo-funcional.md` para ver tudo que foi entregue.
3. Ler `04-arquitetura.md` e `05-fluxos-de-ia-e-agentes.md` para entender as decisoes centrais.
4. Usar `10-como-rodar.md` para executar localmente.
5. Consultar `12-testes-validacao.md` para validar a entrega.

Enquanto os capitulos seguintes ainda nao forem escritos, o README raiz e a documentacao OpenAPI em `/docs` continuam sendo as referencias praticas para execucao e contratos.

Proximo capitulo

O proximo documento planejado e `02-escopo-funcional.md`, que detalhara o que cada fluxo faz, quais recursos estao implementados e quais responsabilidades ficam fora do escopo atual.

Escopo Funcional

Objetivo deste capítulo

Este capítulo descreve o que a solução entrega do ponto de vista funcional. Aqui o foco não é explicar a arquitetura interna, mas deixar claro quais fluxos existem, para que servem, como se relacionam com o case técnico e quais recursos de apoio foram implementados ao redor deles.

Visão geral do escopo

O CPJ-Cobrança AI foi construído como uma plataforma de apoio ao processo de desenvolvimento. A entrega principal é uma API REST com agentes de IA capazes de analisar artefatos técnicos e retornar respostas estruturadas, rastreáveis e persistentes.

O escopo funcional está organizado em quatro grupos:

- **Fluxos obrigatórios do case:** review, compliance, document e tests.
- **Diferenciais de automação:** batch, streaming SSE, webhooks, review de Pull Request e geração de testes por Pull Request.
- **Governança e rastreabilidade:** histórico, analytics, prompts versionados, catálogo de modelos, cache, telemetria e persistência.
- **Experiência operacional:** Swagger/OpenAPI, arquivo `.http`, Docker Compose e painel web admin.

Leitura do escopo na perspectiva do case

Para um avaliador técnico, este capítulo deve ser lido em três camadas:

- **o que era obrigatório no enunciado** e precisa existir para o case estar funcional;
- **o que amplia a entrega além do mínimo pedido**, aumentando o valor técnico e a proximidade com um cenário real de uso;
- **o que ainda não faz parte desta versão**, mas aparece como evolução natural para um produto mais maduro.

Na pratica, os fluxos `review`, `compliance`, `document` e `tests`, junto com `GET /health` e os endpoints de historico, representam o nucleo obrigatorio do case. Os demais recursos mostram como a solucao foi estendida para melhorar operacao, avaliacao, governanca e uso no dia a dia.

Fluxos obrigatorios do case

Esta secao descreve o coracao funcional pedido no enunciado. Sem esses fluxos, o case nao estaria completo do ponto de vista da entrega minima esperada.

Code Review Automatizado

Endpoint principal:

- `POST /api/v1/review`

Este fluxo recebe um trecho de codigo, a linguagem e um contexto opcional. A resposta apresenta uma avaliacao estruturada com qualidade geral, nota, problemas encontrados, sugestoes, pontos positivos e resumo.

No case, esse fluxo deveria verificar pontos como clareza de nomenclatura, tratamento de erros, vazamentos de recurso, complexidade percebida e padroes comuns de seguranca. A implementacao amplia esse escopo com:

- suporte a TypeScript, JavaScript, Python e PHP;
- roteamento por linguagem;
- tools deterministicas antes das chamadas ao LLM;
- agentes especialistas para diferentes criterios de revisao;
- agregacao final da analise;
- persistencia de execucao, steps e telemetria;
- cache por hash para evitar reprocessar entradas identicas.

Avaliacao de Aderencia a Tarefa

Endpoint principal:

- `POST /api/v1/compliance`

Este fluxo recebe uma descrição de tarefa, o código implementado e a linguagem. A resposta informa se a implementação está aderente, calcula um score de conformidade e separa requisitos cobertos, ausentes e parcialmente atendidos.

O objetivo funcional é cruzar o que a tarefa pedia com o que o código realmente faz. Isso ajuda a identificar lacunas de implementação, comportamentos parciais, requisitos ignorados e pontos que exigem revisão humana.

Geracao de Documentacao Tecnica ou Operacional

Endpoint principal:

- `POST /api/v1/document`

Este fluxo recebe código, linguagem e tipo de documentação. O tipo pode orientar uma documentação mais técnica, voltada a desenvolvedores, ou mais operacional, voltada a squads, produto ou pessoas que precisam entender o comportamento sem entrar nos detalhes internos do código.

A resposta estrutura título, descrição, entradas, saídas, efeitos colaterais, exemplo de uso e observações. O foco é transformar código em documentação útil, revisável e reaproveitável.

Geracao de Testes Unitarios

Endpoint principal:

- `POST /api/v1/tests`

Este fluxo recebe código, linguagem e framework de teste desejado. A resposta retorna o framework, um arquivo de teste completo, uma lista de casos cobertos e dicas de cobertura para revisão manual.

O objetivo é acelerar a criação de testes para caminhos felizes, casos de borda e situações de erro, sem substituir a revisão técnica de quem conhece o domínio do módulo.

Diferenciais implementados

Os itens abaixo não eram obrigatórios no enunciado, mas foram implementados para tornar a solução mais completa, mais demonstrável e mais próxima de um uso real em ambiente técnico.

Streaming do review

Endpoint:

- `POST /api/v1/review/stream`

Este endpoint executa o mesmo fluxo de review, mas responde via Server-Sent Events. Ele permite acompanhar eventos como inicio, steps intermediarios, resultado, erro e finalizacao.

Esse recurso foi implementado como diferencial de experiencia de uso para processamentos que podem demorar mais do que uma request simples.

Execucao em lote

Endpoint:

- `POST /api/v1/batch`

O batch permite enviar varios itens em uma unica requisicao e executar fluxos como `review`, `compliance`, `document` e `tests` em sequencia.

Funcionalmente, ele ajuda em cenarios de avaliacao ou automacao nos quais varios artefatos precisam ser processados juntos. A resposta consolida o status do lote e o resultado individual de cada item.

Review de Pull Request

Endpoint:

- `POST /api/v1/review/pull-request`

Este fluxo amplia o review de codigo para o contexto real de Pull Requests no GitHub. Ele recebe a URL do Pull Request, pode considerar uma chave Jira opcional e analisa o diff com base em criterios como padroes de codigo, seguranca, consistencia com o projeto e aderencia aos criterios da tarefa.

Esse recurso nao era obrigatorio no enunciado original, mas aproxima a solucao do uso cotidiano de um time tecnico.

Geracao de testes por Pull Request

Endpoint:

- `POST /api/v1/tests/pull-request`

Este fluxo busca o Pull Request no GitHub, infere a linguagem principal pelos arquivos alterados, identifica funcoes, branches e casos de erro criticos no diff e gera testes unitarios focados nas alteracoes.

Ele complementa o fluxo `tests`, que trabalha com codigo enviado diretamente na request.

Webhook callback

Quando `WEBHOOK_CALLBACK_URL` esta configurado, os fluxos principais podem notificar uma URL externa ao concluir com sucesso ou falha.

O webhook nao substitui a resposta HTTP principal. Ele funciona como mecanismo de integracao para processamentos longos ou automacoes externas, registrando o step do callback no historico.

Retry configuravel com backoff

As chamadas externas possuem retry configuravel com backoff exponencial. Isso cobre chamadas ao LLM via OpenRouter, consultas de telemetria/precos no OpenRouter, chamadas ao GitHub, consultas ao Jira e callbacks de webhook.

As variaveis `EXTERNAL_RETRY_ATTEMPTS` e `EXTERNAL_RETRY_BASE_DELAY_MS` controlam a quantidade de tentativas e o intervalo base entre elas.

Rastreabilidade e governanca

Historico de execucoes

Endpoints:

- `GET /api/v1/history`
- `GET /api/v1/history/:id`

O historico registra as execucoes dos fluxos, incluindo tipo, status, payloads, resultado, duracao, cache hit, steps intermediarios e telemetria quando disponivel.

Isso permite auditar como uma resposta foi produzida e facilita depuracao, demonstracao e avaliacao tecnica.

Analytics de uso

Endpoint:

- `GET /api/v1/analytics/usage`

O modulo de analytics agrega informacoes operacionais como uso, tokens e custos. Ele existe para transformar a telemetria persistida em uma visao mais facil de acompanhar no painel ou em consultas administrativas.

Prompts versionados

Endpoints:

- `GET /api/v1/prompts`
- `GET /api/v1/prompts/:flowType/active`
- `GET /api/v1/prompts/:flowType/:version`
- `POST /api/v1/prompts`
- `POST /api/v1/prompts/:flowType/:version/activate`

Os prompts podem ser cadastrados, consultados e ativados por fluxo. Isso evita que toda evolucao de comportamento do agente dependa de alterar codigo e republicar a aplicacao.

Tambem e possivel informar `prompt_version` em requests especificas para usar uma versao diferente da ativa.

Catalogo de modelos

Endpoints:

- `GET /api/v1/models`
- `GET /api/v1/models/default`
- `POST /api/v1/models`
- `PATCH /api/v1/models/:id`

- `DELETE /api/v1/models/:id`

O catalogo de modelos controla quais modelos podem ser usados pela API, qual modelo esta ativo e qual e o padrao global. Requests individuais podem informar `model` para sobrescrever o padrao, desde que o modelo esteja cadastrado e ativo.

Cache por hash

Os fluxos principais usam hash do payload para reutilizar resultados de execucoes bem-sucedidas quando a entrada e identica. Isso reduz custo, latencia e chamadas repetidas ao provedor LLM.

Mesmo em cache hit, uma nova execucao pode ser registrada apontando para a execucao original, preservando rastreabilidade.

Experiencia operacional

Healthcheck

Endpoint:

- `GET /health`

O healthcheck permite validar rapidamente se a API subiu. Ele e usado tanto no setup local quanto na validacao via Docker.

OpenAPI e Swagger UI

Endpoint:

- `GET /docs`

A API publica documentacao interativa para facilitar exploracao dos endpoints, contratos e respostas esperadas.

Exemplos manuais

O arquivo [requests/cpj-cobranca-api.http](#) concentra exemplos funcionais para uso manual durante desenvolvimento, avaliacao e demonstracao.

Painel web admin

O painel em [apps/web](#) oferece uma camada visual sobre a API. Ele foi pensado como console tecnico para:

- visualizar dashboard e metricas;
- consultar historico;
- gerenciar prompts;
- gerenciar modelos;
- executar fluxos guiados;
- verificar status da API e acesso ao Swagger.

O painel nao substitui a API. Ele melhora a experiencia de avaliacao e operacao dos recursos implementados.

Evolucoes fora do escopo obrigatorio nesta versao

Os itens abaixo nao eram requisitos obrigatorios do case. Eles aparecem aqui como limites assumidos desta entrega e como caminhos naturais de evolucao:

- autenticao e autorizacao de usuarios finais;
- controle multi-tenant;
- fila assincrona com worker dedicado;
- streaming SSE para todos os fluxos, ja que nesta versao ele foi implementado apenas no fluxo de review;
- edicao visual avancada de prompts;
- avaliacao automatica de qualidade das respostas geradas pelo LLM;
- suporte local via Ollama como provedor padrao.

Esses pontos podem ser evoluídos depois, mas nao prejudicam a avaliacao do case, porque os requisitos obrigatorios foram entregues e varios diferenciais relevantes tambem ja fazem parte da solucao atual.

Relacao com os proximos capitulos

Este capitulo explica o que a solucao faz. Os proximos documentos detalham como ela foi construida:

- [03-stack-e-decisoes.md](#): tecnologias e justificativas.
- [04-arquitetura.md](#): organizacao interna e fluxo tecnico.
- [05-fluxos-de-ia-e-agentes.md](#): engines, graphs, agents e tools.
- [06-api-contratos-e-exemplos.md](#): contratos HTTP e exemplos completos.

Stack e Deciso es Tecnicas

Objetivo deste capitulo

Este capitulo explica quais tecnologias foram escolhidas para o case CPJ-Cobrança AI e por que elas fazem sentido para a entrega proposta.

O foco aqui não é apenas listar ferramentas. A ideia é mostrar como cada decisão ajuda a atender os requisitos do case, reduzir complexidade acidental, melhorar a avaliação técnica da entrega e deixar o projeto pronto para evoluir.

Visão geral da stack

Camada	Tecnologia principal	Papel no projeto
Runtime backend	Node.js 22	Execução da API e ferramentas de build/dev
Linguagem backend	TypeScript 5	Tipagem, contratos e manutenção
Framework HTTP	Fastify 5	API REST, plugins, middlewares e OpenAPI
Validação	Zod	Schemas de entrada e saída
Persistência	Prisma + PostgreSQL 16	Histórico, prompts, modelos, cache e telemetria
Orquestração de IA	LangGraph.js + LangChain.js	Fluxos, agentes, tools e structured output
Provedor LLM	OpenRouter	Acesso a modelos e telemetria de uso/custo

Observabilidade de IA	LangSmith	Tracing opcional
Build backend	tsup	Empacotamento rapido para producao
Testes backend	Vitest	Testes unitarios e de integracao leve
Lint	ESLint 9	Padronizacao e qualidade estatica
Containers	Docker + Docker Compose	Execucao local e deploy
Frontend	Next.js 16 + React 19	Painel administrativo
UI do frontend	Ant Design 6	Componentes visuais do painel
Graficos do painel	Ant Design Charts	Custos, tokens e metricas operacionais

Leitura da stack sob a otica do case

O case nao exigia uma arquitetura corporativa complexa. Ele exigia algo mais importante: uma solucao que subisse, fosse testavel, tivesse persistencia, integrasse IA de forma util e viesse acompanhada de documentacao clara.

Por isso, as escolhas tecnicas seguiram alguns principios:

- usar tecnologias maduras e amplamente conhecidas;
- reduzir atrito para rodar localmente e em Docker;
- preservar clareza para avaliacao de codigo;
- separar bem responsabilidades sem exagerar na abstracao;
- permitir evolucao real em cima da base entregue.

Backend

Node.js 22

O backend roda sobre Node.js 22, que oferece um ambiente moderno, estavel e adequado para aplicacoes HTTP, integracoes externas e orquestracao de fluxos de IA.

Essa escolha ajuda o case em tres pontos:

- simplifica o uso de bibliotecas atuais do ecossistema TypeScript;
- conversa bem com Fastify, Prisma, LangChain e LangGraph;
- reduz barreiras para rodar localmente, em CI e em container.

TypeScript 5

TypeScript foi escolhido para dar previsibilidade ao projeto inteiro: contratos HTTP, estruturas retornadas pelos agentes, modelos persistidos e integracoes internas.

No contexto do case, isso importa porque a avaliacao considera qualidade de codigo, clareza arquitetural e confiabilidade da entrega. A tipagem ajuda a:

- documentar intencoes no proprio codigo;
- reduzir ambiguidade entre schema, implementacao e testes;
- facilitar manutencao conforme novos fluxos forem adicionados.

O projeto combina TypeScript com Zod para aproximar tipo estatico e validacao em runtime, evitando depender apenas do compilador para entradas externas.

Fastify 5

Fastify foi escolhido como framework da API por ser enxuto, rapido e muito bom para projetos modulares baseados em plugins, rotas e schemas.

Ele atende bem ao case porque permite:

- montar uma API REST clara e organizada;
- registrar middlewares, CORS, rate limit e seguranca com pouco atrito;

- integrar Swagger/OpenAPI de forma nativa;
- manter o código de bootstrap pequeno e legível.

Em uma entrega de case, essa clareza pesa bastante: o avaliador consegue entender facilmente como a aplicação sobe, como as rotas entram e como os módulos se conectam.

Zod

Zod foi usado para validar payloads de entrada e estruturar dados de saída dos fluxos. Essa escolha conversa diretamente com um dos riscos naturais de projetos com LLM: receber dados livres demais ou respostas inconsistentes.

Com Zod, a aplicação ganha:

- validação previsível nas bordas da API;
- contratos reutilizáveis entre backend, testes e documentação;
- menor risco de aceitar requests inválidas ou propagar estruturas quebradas.

Persistência

PostgreSQL 16

PostgreSQL foi escolhido como banco relacional principal porque o projeto precisa guardar histórico de execuções, steps, telemetria, prompts versionados, catálogo de modelos e dados de batch de forma consistente.

Para o case, um banco relacional faz sentido porque:

- o histórico precisa ser consultável e auditável;
- prompts e modelos possuem relações e estados bem definidos;
- a avaliação valoriza modelagem coerente e persistência real.

Prisma

Prisma foi adotado como camada de acesso a dados. A escolha equilibra produtividade, legibilidade e segurança de tipos sem esconder totalmente a modelagem do banco.

Ele foi especialmente útil aqui para:

- manter schema e código alinhados;
- simplificar migrations e seed inicial;
- facilitar queries de histórico, analytics e governança;
- reduzir a quantidade de SQL manual no fluxo principal.

O uso de Prisma também melhora a experiência do avaliador, porque o schema fica centralizado e mais fácil de ler do que uma camada de persistência espalhada em strings SQL soltas.

IA e orquestração

LangGraph.js

LangGraph foi escolhido para modelar os fluxos de IA como grafos explícitos, e não como uma única chamada monolítica ao modelo.

Isso combina com o problema do caso porque vários fluxos possuem etapas distintas: validações, roteamento por linguagem, tools determinísticas, especialistas e agregação final.

Os ganhos principais são:

- visibilidade de etapas;
- melhor separação entre responsabilidades;
- possibilidade de registrar steps no histórico;
- facilidade para evoluir fluxos sem reescrever tudo.

LangChain.js

LangChain foi usado como camada de integração com modelo, structured output e composição de comportamento dos agentes.

Neste projeto, ele funciona como complemento do LangGraph:

- LangGraph organiza o fluxo;
- LangChain ajuda a padronizar a conversa com o LLM.

Essa combinacao foi uma escolha boa para o case porque permitiu construir algo mais robusto do que um wrapper simples de `fetch`, sem transformar a entrega em uma plataforma excessivamente abstrata.

OpenRouter

OpenRouter foi escolhido como provedor LLM por permitir acesso a diferentes modelos por uma interface unica, mantendo flexibilidade de custo e troca de modelo.

Para o case, isso tem varias vantagens:

- facilita documentar modelo padrao e alternativas;
- reduz acoplamento a um unico vendor;
- combina bem com o catalogo de modelos persistido no banco;
- permite capturar metadados de uso e custo quando disponiveis.

O projeto ainda adiciona retry configuravel com backoff nas chamadas externas, o que melhora resiliencia sem exigir um provedor proprietario adicional.

LangSmith

LangSmith entra como tracing opcional. Ele nao e necessario para rodar o projeto, mas foi mantido como diferencial para observabilidade de fluxos de IA.

Essa decisao e importante porque equilibra dois objetivos:

- oferecer um caminho de diagnostico mais avancado;
- nao bloquear setup local ou avaliacao quando a chave nao estiver disponivel.

Qualidade de codigo e entrega

Vitest

Vitest foi escolhido para testes por ter boa ergonomia no ecossistema TypeScript, execucao rapida e sintaxe simples.

Ele cobre bem o que o case precisa demonstrar:

- validacao de contratos;
- verificacao de rotas;
- testes de servicos e repositórios;
- protecao contra regressao em integrações e config.

ESLint 9

ESLint ajuda a manter consistencia e legibilidade do codigo. Em um case tecnico, isso importa nao apenas por padrao de estilo, mas porque pequenas inconsistencias acabam dificultando leitura e revisao.

tsup

tsup foi escolhido para o build do backend por ser simples, rapido e suficiente para uma API Node.js deste porte.

Essa decisao evita um pipeline de build pesado demais e deixa claro que a prioridade aqui e a entrega funcional do servico, nao uma sofisticacao desnecessaria no empacotamento.

Frontend e experiencia operacional

Next.js 16 + React 19

O painel web foi construido com Next.js e React para oferecer uma interface tecnica de apoio ao avaliador e ao operador da API.

Essa escolha foi util porque:

- facilita criar paginas administrativas rapidamente;
- funciona bem em uma estrutura de workspace junto com a API;
- entrega uma interface moderna sem exigir uma aplicacao frontend isolada e excessivamente customizada.

No contexto do case, o painel nao substitui a API, mas melhora muito a avaliacao da entrega ao mostrar historico, prompts, modelos, status e execucao guiada dos fluxos.

Ant Design 6

Ant Design foi escolhido para acelerar a construção de uma interface com cara de ferramenta operacional, e não de landing page.

Isso combina com o público do projeto:

- avaliador técnico;
- desenvolvedor;
- pessoa operando os fluxos ou inspecionando histórico.

A biblioteca oferece tabelas, formulários, layout, componentes de feedback e elementos administrativos prontos, o que ajudou a manter foco na funcionalidade em vez de gastar tempo excessivo com design do zero.

Ant Design Charts

Os gráficos foram usados para apoiar a visualização de custos, tokens e uso no painel. É uma escolha pragmática: reaproveita o ecossistema visual da própria stack do frontend e acelera a entrega de métricas operacionais.

Containers, setup e deploy

Docker e Docker Compose

Docker e Docker Compose foram escolhidos porque o case exigia uma entrega containerizada e com setup reproduzível.

Essa escolha ajuda diretamente nos critérios de avaliação:

- sobe API, banco e painel de forma consistente;
- reduz diferenças entre ambiente local e ambiente de deploy;
- simplifica demonstração;
- facilita automação no GitHub Actions e deploy em VPS.

Também foi uma decisão importante para confiabilidade da entrega: quando a documentação diz `docker compose up --build`, o projeto de fato foi preparado para seguir esse caminho.

Trade-offs assumidos

Nem toda escolha foi sobre maximizar poder tecnico. Algumas foram sobre manter a solucao avaliavel e sustentavel dentro do tempo do case.

Os principais trade-offs foram:

- **usar Fastify em vez de um framework mais opinativo:** menos estrutura pronta, mas mais controle e menos peso;
- **usar Prisma em vez de SQL manual em toda a aplicacao:** mais produtividade e legibilidade, com menor controle fino em consultas muito especificas;
- **usar OpenRouter em vez de integrar varios providers diretamente:** mais simplicidade operacional, com dependencia de um gateway unico;
- **usar painel admin com Ant Design em vez de frontend altamente customizado:** mais velocidade de entrega e melhor foco no uso tecnico;
- **usar LangGraph/LangChain sem exagerar em camadas proprietarias:** melhor estrutura para os fluxos, preservando legibilidade do codigo.

Decisao central da stack

Se fosse resumir a logica da stack em uma frase, seria esta:

construir uma base tecnica moderna, testavel e rastreavel, usando ferramentas conhecidas o suficiente para facilitar avaliacao e evolucao, sem transformar o case em uma arquitetura maior do que o problema pedia.

Relacao com os proximos capitulos

Depois deste capitulo, a leitura natural e:

- [04-arquitetura.md](#), para entender como essa stack foi organizada no codigo;
- [05-fluxos-de-ia-e-agentes.md](#), para detalhar o papel de LangGraph, LangChain, tools, especialistas e aggregator;
- [10-como-rodar.md](#), para ver a stack em execucao local e em Docker.

Arquitetura

Objetivo deste capítulo

Este capítulo descreve como o projeto foi organizado internamente para atender o case técnico do CPJ-Cobrança AI. O foco aqui é mostrar a estrutura do sistema como arquitetura de software: camadas, módulos, fluxo de uma request, responsabilidades e pontos de integração.

O objetivo não é detalhar cada algoritmo ou cada prompt. A ideia é permitir que um avaliador técnico entenda rapidamente:

- como a aplicação sobe;
- como as dependências são montadas;
- como os fluxos foram separados;
- como a API conversa com banco, LLM e painel web;
- onde estão os principais pontos de extensão e rastreabilidade.

Visão arquitetural

Em alto nível, a solução é composta por quatro blocos principais:

- **cliente:** consumidores HTTP e painel web;
- **API backend:** camada principal de orquestração e execução dos fluxos;
- **persistência:** PostgreSQL via Prisma para histórico, telemetria, prompts, modelos e batch;
- **integrações externas:** OpenRouter, LangSmith opcional, GitHub, Jira e webhook callback.

```
flowchart LR
  Client["Cliente HTTP / Swagger / arquivo .http"]
  Web["Painel web Next.js"]
  API["API Fastify"]
  Shared["Contratos Zod + middlewares + config"]
  Modules["Módulos de domínio e fluxos"]
  DB["PostgreSQL + Prisma"]

  Client --> API
  Web --> API
  API --> Shared
  Shared --> Modules
  Modules --> DB
```

```
LLM["OpenRouter / modelos LLM"]
Trace["LangSmith (opcional)"]
GitHub["GitHub API"]
Jira["Jira API"]
Webhook["Webhook externo"]
Client --> API
Web --> API
API --> Shared
API --> Modules
Modules --> DB
Modules --> LLM
Modules --> Trace
Modules --> GitHub
Modules --> Jira
Modules --> Webhook
```

Principio estrutural da arquitetura

A arquitetura foi desenhada para equilibrar tres necessidades do case:

- **clareza para avaliacao tecnica;**
- **separacao de responsabilidades;**
- **entrega real, rodavel e extensivel.**

Por isso, o projeto nao foi modelado como um unico servico chamando LLM de forma direta. Em vez disso, cada capacidade foi organizada em modulos com fronteiras claras, contratos compartilhados e uma camada de engine responsavel por executar o fluxo real.

Camadas da aplicacao

1. Entrada e composicao

Os arquivos `src/server.ts` e `src/app.ts` sao o ponto de entrada da aplicacao.

Nessa camada acontecem quatro coisas principais:

- carregamento de variaveis de ambiente;
- criacao da instancia Fastify;
- registro de plugins e middlewares globais;

- registro das rotas por modulo.

Essa decisao centraliza o bootstrap e evita espalhar configuracao critica pelo projeto.

2. Shared

O diretorio `src/shared/` concentra tudo o que atravessa varios modulos:

- `config/`: leitura e validacao de ambiente;
- `contracts/`: schemas Zod e tipos compartilhados;
- `middlewares/`: tratamento global de erro, contexto de request e seguranca;
- `utils/`: hash, datas e retry compartilhado.

Essa camada existe para evitar duplicacao e manter consistencia entre rotas, servicos, testes e documentacao.

3. Infrastructure

O diretorio `src/infrastructure/` concentra integracoes transversais que nao pertencem a um fluxo especifico:

- `database/`: plugin Prisma para o Fastify;
- `logging/`: configuracao de logger;
- `openapi/`: registro de Swagger/OpenAPI;
- `errors/`: tratamento e normalizacao de erros.

E uma camada de apoio tecnico. Ela sustenta a API, mas nao concentra regra de negocio nem detalhes funcionais dos fluxos.

4. Modules

O diretorio `src/modules/` concentra os blocos funcionais reais do sistema.

Ele foi dividido em dois grandes grupos:

- **modulos de fluxo:** `review`, `compliance`, `document`, `tests`, `batch`;

- **modulos de apoio e governanca:** `history`, `analytics`, `prompts`, `models`, `executions`, `agent`.

Essa divisao ajuda a separar:

- o que entrega valor funcional direto ao case;
- o que viabiliza rastreabilidade, configuracao e observabilidade.

Organizacao por modulo

Cada modulo segue, em maior ou menor grau, o mesmo padrao estrutural:

- `routes/`: registra endpoints Fastify;
- `controllers/`: recebe request, valida payload e envia response;
- `services/`: coordena o uso do fluxo a partir da perspectiva HTTP;
- `engines/`: executa a logica principal do fluxo;
- `graphs/`: define orquestracao em LangGraph quando aplicavel;
- `agents/`: encapsula especialistas baseados em LLM;
- `tools/`: validacoes ou analises deterministicas;
- `prompts/`: catalogos e templates de prompt;
- `docs/`: schemas OpenAPI por rota.

Nem todo modulo possui todas essas pastas, mas o padrao geral se repete.

Fluxo de uma request

O ciclo de request segue uma sequencia clara da borda HTTP ate a persistencia e o retorno estruturado.

```
sequenceDiagram
    participant Client as Cliente
    participant Route as Route
    participant Controller as Controller
    participant Service as Service
```

```
participant Engine as Engine
participant Graph as Graph
participant LLM as OpenRouter
participant DB as Prisma/PostgreSQL
Client->>Route: POST /api/v1/review
Route->>Controller: handler Fastify
Controller->>Service: valida payload com zod
Service->>Engine: execute(input)
Engine->>DB: consulta cache / cria execucao pendente
Engine->>Graph: invoke(...)
Graph->>LLM: chamadas estruturadas ao modelo
Graph->>Engine: output estruturado
Engine->>DB: grava steps, status e telemetria
Engine->>Service: resposta final
Service->>Controller: output
Controller->>Client: JSON HTTP 200
```

Esse fluxo também ajuda a entender uma decisão importante da arquitetura: o controller não conhece detalhes de LLM, banco ou grafo. Ele apenas recebe, valida e delega.

Papel de cada camada no request lifecycle

Routes

As rotas fazem a ligação entre a URL HTTP e o controller correspondente. Também registram schemas OpenAPI e configurações do Fastify, como `attachValidation`.

Exemplo concreto: `src/modules/review/routes/index.ts`

Controllers

Os controllers transformam a request HTTP em chamada de aplicação. Eles:

- parseiam e validam payloads;
- convertem erro de validação em resposta apropriada;
- chamam o service correto;
- entregam a resposta HTTP final.

Exemplo concreto: `src/modules/review/controllers/index.ts`

Services

Os services funcionam como fachada do fluxo para a camada HTTP. Eles escolhem qual engine usar, resolvem modo de execucao especial quando necessario e expõem uma interface mais simples para o controller.

No caso de `review`, por exemplo, o service tambem trata o modo streaming SSE sem jogar essa responsabilidade para o engine inteiro.

Engines

Os engines sao o centro operacional dos fluxos. Eles concentram:

- verificacao de cache;
- criacao de execucao pendente;
- chamada do grafo principal;
- marcacao de sucesso ou falha;
- gravacao de steps e telemetria;
- notificacao de webhook quando configurado.

Exemplo concreto: `src/modules/review/engines/review.engine.ts`

Graphs

Os graphs modelam a orquestracao do fluxo. Eles existem porque varios fluxos de IA nao sao apenas uma chamada unica ao modelo: ha selecao de caminho, ferramentas deterministicas, agentes especialistas e agregacao.

Essa camada e especialmente importante no `review`, que possui:

- roteamento por linguagem;
- grafos especificos por linguagem;
- especialistas por criterio de avaliacao;
- aggregator final.

Agents e tools

Os agents encapsulam especialistas baseados em LLM. As tools executam análises determinísticas que complementam ou guiam o fluxo.

Essa combinacao foi escolhida para evitar depender 100% de comportamento livre do modelo. A arquitetura mistura heurísticas previsíveis com análise generativa.

Dependencias e composicao

A composicao principal acontece em `App`, mas cada modulo tambem sabe criar suas proprias dependencias padrao quando recebe um `FastifyInstance` com Prisma registrado.

Isso gera um modelo leve de injecao de dependencias:

- no runtime real, as rotas constroem services e repositories concretos;
- em testes, as dependencias podem ser injetadas manualmente;
- a aplicacao continua simples, sem precisar de um container DI pesado.

Esse padrao aparece com clareza em `src/modules/review/routes/index.ts`, onde o modulo cria `DefaultReviewService`, `ReviewExecutionRepository`, `DefaultPromptsService` e `DefaultModelsService` quando necessario.

Persistencia na arquitetura

A persistencia foi desenhada como parte estrutural da solucao, nao como detalhe acoplado ao fim do fluxo.

O schema Prisma guarda:

- `Execution`: execucao principal do fluxo;
- `ExecutionStep`: steps intermediarios;
- `ExecutionTelemetry`: uso de modelo, tokens e custo;
- `PromptVersion`: versoes de prompt por fluxo e bloco;
- `RegisteredModel` e `GlobalModelSettings`: governanca de modelos;
- `BatchExecution`: resumo de execucoes em lote.

Essa modelagem deixa a arquitetura mais auditável e explica por que a aplicação não trata cada resposta do LLM como algo descartável.

Arquitetura do review como exemplo de referência

O fluxo **review** é o melhor exemplo para entender a arquitetura inteira, porque ele exercita quase todos os componentes do sistema ao mesmo tempo.



Essa estrutura se repete, com variações menores, em **compliance**, **document** e **tests**.

Arquitetura do painel web

O frontend em **apps/web** não replica a lógica dos fluxos. Ele funciona como cliente da API.

Em termos arquiteturais, isso é importante porque preserva uma separação clara:

- a API é a fonte de verdade funcional;
- o painel é uma camada de operação e visualização.

Isso reduz duplicação de regra e evita que parte da lógica do caso fique espalhada entre backend e frontend.

Middlewares e preocupações transversais

Algumas responsabilidades aparecem em toda a aplicacao e por isso foram centralizadas em middlewares e infraestrutura compartilhada:

- tratamento global de erros;
- contexto de request;
- seguranca HTTP;
- OpenAPI/Swagger;
- logger;
- conexao Prisma.

Esse desenho evita repetir setup tecnico em cada modulo e ajuda a manter a arquitetura coesa.

Por que essa arquitetura funciona bem para o case

Esta arquitetura foi uma boa escolha para o case por cinco motivos:

1. deixa o bootstrap simples e facil de auditar;
2. separa HTTP, execucao de fluxo, persistencia e integracoes externas;
3. permite testes por camada;
4. acomoda bem fluxos com IA sem reduzir tudo a uma unica chamada de prompt;
5. cria base real para evolucao futura sem inflar demais a entrega.

Limites assumidos na arquitetura atual

A arquitetura foi pensada para uma entrega de case e, por isso, assume alguns limites conscientes:

- nao ha mensageria externa nem fila dedicada;
- os fluxos rodam de forma sincrona no backend principal;
- nao existe separacao por microservicos;
- o painel web depende integralmente da API para dados operacionais;
- o modelo de injecao de dependencias e manual, e nao baseado em framework DI.

Esses limites não empobrecem a entrega. Eles mantêm a solução legível, demonstrável e suficiente para o escopo pedido.

Relação com os próximos capítulos

Depois deste capítulo, os próximos documentos aprofundam dois pontos específicos desta arquitetura:

- [05-fluxos-de-ia-e-agentes.md](#): detalha graphs, tools, especialistas e aggregator;
- [07-dados-cache-telemetria.md](#): detalha a modelagem persistida no banco.

Fluxos de IA e Agentes

Objetivo deste capítulo

Este capítulo detalha como os fluxos de IA funcionam dentro do projeto. O foco não é apenas dizer que a API "chama um modelo", mas explicar como a aplicação combina:

- tools determinísticas;
- prompts versionados;
- agentes especialistas;
- structured output;
- grafos LangGraph;
- persistência de steps;
- telemetria e retry.

Esse é o coração técnico da entrega, porque é aqui que a solução deixa de ser um wrapper simples de LLM e passa a operar como um conjunto de fluxos especializados.

Visão geral dos fluxos

Os fluxos com IA do projeto podem ser lidos em três grupos:

- **fluxo de review**, que é o mais rico e usa roteamento por linguagem, especialistas e aggregator;
- **fluxos lineares**, como **compliance**, **document** e **tests**, que seguem a ideia tool -> agente;
- **fluxos de Pull Request**, que combinam integrações externas, preparação de payload e avaliação estruturada.

Padrão geral de execução

Apesar das diferenças entre os fluxos, existe um padrão arquitetural comum:

1. a request entra pelo controller e chega ao service;
2. o engine resolve prompt e modelo;
3. o engine consulta cache quando aplicavel;
4. o grafo executa steps determinísticos e/ou agentes LLM;
5. as respostas retornam em formato estruturado;
6. o engine persiste status, steps, telemetria e callback de webhook;
7. a API devolve o resultado final.

```

flowchart LR
    Input["Request Validada"] --> Engine["Engine do Fluxo"]
    Engine --> Prompt["Prompt runtime"]
    Prompt --> Model["Modelo resolvido"]
    Model --> Cache["Cache por hash"]
    Cache --> Graph["LangGraph / fluxo"]
    Graph --> Tools["Tools determinísticas"]
    Tools --> Agents["Agentes LLM"]
    Agents --> Output["Saída estruturada"]
    Output --> Persist["Historico + Steps + Telemetria"]
    Persist --> Input
  
```

```

Input --> Engine
Engine --> Prompt
Engine --> Model
Engine --> Cache
Cache --> Graph
Graph --> Tools
Graph --> Agents
Agents --> Output
Output --> Persist
  
```

Structured output como base do comportamento

Um dos pilares da solução é o uso de saída estruturada em vez de respostas textuais livres. A classe `src/modules/agent/llm/structured-output.runner.ts` faz esse papel.

Na prática, isso significa que cada agente ou aggregator:

- recebe mensagens `system` e `user`;
- responde segundo um schema Zod esperado;
- passa por validação antes de a resposta seguir no fluxo.

Essa escolha reduz ambiguidades, melhora a confiabilidade da API e faz com que os contratos dos endpoints conversem melhor com testes, OpenAPI e persistencia.

Tools determinísticas versus agentes LLM

O projeto não delega tudo ao modelo. Ele combina duas categorias de execução:

Tools determinísticas

As tools são responsáveis por sinais objetivos e previsíveis. Elas rodam sem LLM e normalmente operam com heurísticas, regexes ou análise simples do input.

Exemplo no review:

- detecção de logs com dados sensíveis;
- detecção de interpolação SQL evidente.

Exemplo em outros fluxos:

- extração de requisitos em **compliance**;
- sinais de API pública em **document**;
- candidatos de comportamento em **tests**.

Agentes LLM

Os agentes entram quando a tarefa exige interpretação, consolidação de contexto ou julgamento técnico mais semântico.

Eles recebem:

- o input original;
- o contexto da linguagem;
- os achados das tools;
- o prompt do bloco correspondente.

Essa divisão é importante porque evita tratar o LLM como oráculo absoluto.

Fluxo de review

O fluxo `review` é o mais completo do sistema e funciona como referência para o resto da arquitetura de IA.

Etapa 1: roteamento por linguagem

O `ReviewFlowGraph` recebe a request e primeiro passa pelo node `language_router`.

Essa etapa identifica a linguagem do input e direciona para um dos grafos específicos:

- `review_typescript`
- `review_javascript`
- `review_python`
- `review_php`

```
Flowchart ID
A["Review input"] --> B["language_router"]
B --> C["review_typescript"]
B --> D["review_javascript"]
B --> E["review_python"]
B --> F["review_php"]
```

Isso permite adequar perfis, contexto e leitura do código sem misturar regras de linguagens diferentes em um único fluxo genérico.

Etapa 2: tools determinísticas

Dentro do grafo da linguagem, o primeiro passo é `deterministic_tools`.

Esse passo gera achados objetivos que depois alimentam os agentes especialistas. Em vez de pedir ao LLM que redescubra tudo do zero, a aplicação já entrega parte do terreno preparado.

Etapa 3: especialistas paralelos

Depois das tools, o fluxo dispara especialistas independentes:

- `naming_clarity_agent`
- `error_handling_agent`

- `resource_leak_agent`
- `complexity_agent`
- `security_agent`

Cada um recebe o mesmo contexto base, mas com uma missão diferente.

```
flowchart TD
    A["deterministic_tools"] --> B["naming_clarity_agent"]
    A --> C["error_handling_agent"]
    A --> D["resource_leak_agent"]
    A --> E["complexity_agent"]
    A --> F["security_agent"]
    B --> G["review_aggregator_agent"]
    C --> G
    D --> G
    E --> G
    F --> G
```

Essa abordagem traz duas vantagens:

- reduz a chance de uma resposta única ignorar dimensões importantes;
- deixa a análise mais observável e modular.

Etapa 4: aggregator final

O `review_aggregator_agent` recebe:

- código original;
- contexto opcional do usuário;
- achados determinísticos;
- saídas dos especialistas.

Ele é responsável por produzir a resposta final do endpoint, no schema `ReviewResponse`.

Esse aggregator não repete simplesmente os especialistas. Ele consolida, remove redundância, organiza severidades e constrói um parecer único.

Prompts no review

O review usa multiplos blocos de prompt:

- um por especialista;
- um para o aggregator.

Esses blocos podem vir de duas fontes:

- conjunto versionado armazenado no banco;
- fallback legado em catalogos locais quando nao ha resolver persistido.

Isso permite ajustar comportamento dos especialistas sem precisar alterar toda a estrutura do fluxo.

Fluxos lineares: compliance, document e tests

Os fluxos `compliance`, `document` e `tests` seguem uma estrategia mais simples do que o review. Em todos eles, o padrao geral e:

- uma tool prepara sinais ou estrutura parcial;
- um agente LLM gera a resposta final.

Compliance

O `ComplianceFlowGraph` roda:

1. `requirements_extractor`
2. `compliance_agent`

```
Flowchart LR
  A["task description + code"] --> B["requirements_extractor"]
  B --> C["compliance_agent"]
  C --> D["ComplianceResponse"]
```

O primeiro passo extrai requisitos e sinais relevantes; o segundo cruza isso com o codigo e produz score, requisitos cobertos, faltantes e parciais.

Document

O `DocumentFlowGraph` roda:

1. `document_signal_extractor`
2. `document_agent`

Aqui a tool tenta identificar candidatos de API publica, sinais de entrada, saída e comportamento, e o agente monta a documentacao final.

Tests

O `TestsFlowGraph` roda:

1. `tests_signal_extractor`
2. `tests_agent`

Nesse caso, a tool destaca comportamentos, caminhos e sinais que merecem teste, e o agente devolve o arquivo de testes, casos cobertos e dicas de cobertura.

Fluxo de review de Pull Request

O fluxo `review/pull-request` amplia o modelo tradicional de review para um cenario de repositorio real.

Ele combina:

- busca de dados no GitHub;
- busca opcional no Jira;
- carga de padroes locais do projeto;
- preparacao de payload truncado;
- analise por secoes;
- decisao agregada final.

Etapas do fluxo

```

Flowchart ID
A["github fetch"] --> B["jira fetch"]
A --> C["standards load"]
B --> D["analysis payload prepare"]
C --> D
D --> E["code standard agent"]
D --> F["project consistency agent"]
D --> G["security agent"]
D --> H["jira_criteria_agent"]
E --> I["pull_request_review_aggregator"]
F --> I
G --> I
H --> I

```

O que esse fluxo ganha com isso

- o review deixa de olhar apenas um trecho solto de código;
- o diff é analisado com contexto de projeto;
- há cruzamento com critérios de Jira quando informados;
- o sistema retorna seções distintas e um veredito consolidado.

O node `jira_criteria_agent` pode ser marcado como `skipped` quando não existe `jira_issue_key`, o que mantém o fluxo determinístico sem forçar uma integração obrigatória.

Fluxo de testes por Pull Request

O fluxo `tests/pull-request` também usa GitHub como fonte, mas com objetivo diferente: gerar testes focados nas alterações mais críticas do diff.

Etapas do fluxo

```

Flowchart LR
A["github fetch"] --> B["changed code prepare"]
B --> C["critical functions extractor"]
C --> D["tests agent"]
D --> E["TestsResponse"]

```

Comportamentos relevantes

Esse fluxo:

- infere a linguagem principal pelos arquivos alterados;
- trunca payloads grandes para caber no contexto do modelo;
- extrai funcoes, classes, branches e casos de erro criticos;
- usa esse material para orientar a geracao do arquivo de teste final.

Ou seja: nao e apenas "gerar teste para um PR". Existe uma etapa intermediaria de preparacao e priorizacao do que realmente merece cobertura.

Retry com backoff nas chamadas de IA e integracoes

As chamadas externas nao dependem de tentativa unica. O projeto aplica retry configuravel com backoff em pontos como:

- execucoes LLM via `LangChainStructuredOutputRunner`;
- telemetria/precos do OpenRouter;
- GitHub;
- Jira;
- webhook callback.

Isso melhora resiliencia para falhas transitorias sem poluir cada fluxo com logica repetida de repeticao manual.

Telemetria dos fluxos

Os fluxos com LLM usam `AgentTelemetryCollector` para acumular dados de uso de modelo ao longo da execucao.

Ao final, o engine pode persistir:

- provider;
- modelo solicitado;
- modelo realmente usado;
- generation ids;
- tokens de entrada e saida;

- custo total, entrada e saída;
- cache read tokens.

Essa camada é importante porque transforma o uso do LLM em algo mensurável, e não apenas observável por texto de log.

Steps persistidos como trilha de execução

Cada grafo registra steps intermediários quando existe `executionId` e `stepRecorder` disponíveis.

Isso significa que a aplicação guarda não apenas o resultado final, mas também etapas como:

- `language_router`
- `deterministic_tools`
- `security_agent`
- `review_aggregator_agent`
- `github_fetch`
- `analysis_payload_prepare`
- `tests_signal_extractor`

Esse desenho melhora muito a auditabilidade do case e ajuda a explicar a resposta final com mais precisão.

Webhook e camada de engine

Os grafos cuidam da execução interna do fluxo. Já o engine fica responsável por atividades transversais ao redor dele:

- cache;
- persistência de execução;
- mark success / failed;
- telemetria agregada;
- webhook callback.

Isso é importante arquiteturalmente porque evita misturar detalhes de entrega externa dentro dos nodes do grafo.

Diferença entre grafo e engine

Vale registrar de forma bem objetiva:

- **grafo**: descreve como o fluxo pensa;
- **engine**: descreve como o fluxo opera dentro da aplicação.

O grafo decide etapas, especialistas, tools e agregação. O engine decide cache, persistência, telemetria, webhook e integração com o ciclo de execução da API.

Por que essa abordagem faz sentido no case

Essa modelagem foi uma boa escolha para o case porque:

1. evita endpoints opacos demais;
2. permite explicar o comportamento dos agentes com clareza;
3. melhora testabilidade por step e por fluxo;
4. cria base para evoluir prompts, modelos e nodes sem reescrever tudo;
5. entrega algo mais próximo de um sistema de IA operacional do que de um protótipo isolado.

Relação com os próximos capítulos

Depois deste capítulo, a leitura natural é:

- [06-api-contratos-e-exemplos.md](#), para ver como esses fluxos aparecem nos endpoints;
- [07-dados-cache-telemetria.md](#), para entender como cache, steps e telemetria ficam persistidos;

- `08-prompts-modelos-governanca.md`, para detalhar como prompts e modelos são resolvidos em runtime.

API, Contratos e Exemplos

Objetivo deste capítulo

Este capítulo documenta a superfície HTTP da aplicação: endpoints, payloads, respostas, filtros, SSE e exemplos práticos.

O foco é ajudar quem avalia o caso a entender:

- quais rotas existem;
- o que cada uma recebe;
- o que cada uma retorna;
- onde entram `model` e `prompt_version`;
- como os endpoints se relacionam com histórico, batch e governança.

Convencões gerais da API

Base path

As rotas de negócio ficam sob `/api/v1`, com exceção de:

- `GET /health`
- `GET /docs`

Formato de payload

As requests e responses usam JSON, exceto o endpoint de streaming do review, que responde como `text/event-stream`.

Validação

As entradas são validadas com Zod. Quando o payload não atende ao schema esperado, a API responde com erro de validação em vez de deixar o fluxo seguir com dados ambíguos.

Overrides por request

Nos fluxos com IA, dois campos podem aparecer como opcionais:

- `prompt_version`: força uma versão específica de prompt para aquela execução;
- `model`: sobrescreve o modelo padrão global, desde que ele esteja cadastrado e ativo.

Mapa geral dos endpoints

Metodo	Rota	Finalidade
GET	<code>/health</code>	Healthcheck da API
POST	<code>/api/v1/review</code>	Review de código
POST	<code>/api/v1/review/stream</code>	Review via SSE
POST	<code>/api/v1/review/pull-request</code>	Review de Pull Request
POST	<code>/api/v1/compliance</code>	Aderência entre tarefa e código
POST	<code>/api/v1/document</code>	Geração de documentação
POST	<code>/api/v1/tests</code>	Geração de testes
POST	<code>/api/v1/tests/pull-request</code>	Geração de testes a partir de PR
POST	<code>/api/v1/batch</code>	Execução de vários fluxos em lote
GET	<code>/api/v1/history</code>	Lista de execuções
GET	<code>/api/v1/history/:id</code>	Detalhe de uma execução

GET	/api/v1/analytics/usage	Agregados de uso, tokens e custo
GET	/api/v1/prompts	Lista versoes de prompt
GET	/api/v1/prompts/:flowType/active	Busca prompt ativo do fluxo
GET	/api/v1/prompts/:flowType/:version	Busca versao especifica
POST	/api/v1/prompts	Cria nova versao de prompt
POST	/api/v1/prompts/:flowType/:version/activate	Ativa uma versao
GET	/api/v1/models	Lista modelos cadastrados
GET	/api/v1/models/default	Busca modelo padrao global
POST	/api/v1/models	Cadastra modelo
PATCH	/api/v1/models/:id	Atualiza modelo
DELETE	/api/v1/models/:id	Remove modelo nao padrao
GET	/docs	Swagger UI

Endpoints de fluxo

POST /api/v1/review

Faz review estruturado de um trecho de código.

Request

```
{
  "code": "function sum(a, b) { return a + b; }"
```

```
{
  "language": "typescript",
  "context": "Trecho usado em um modulo financeiro",
  "prompt_version": 1,
  "model": "openai/gpt-4o-mini"
}
```

Response

```
{
  "overall_quality": "needs_improvement",
  "score": 7,
  "issues": [
    {
      "severity": "medium",
      "line_hint": "linha 1",
      "description": "A funcao nao explicita contrato de tipos de entrada.",
      "suggestion": "Defina tipos ou valide entradas conforme o contrato esperado."
    }
  ],
  "positives": [
    "Funcao pequena e facil de entender."
  ],
  "summary": "O codigo e simples, mas merece um contrato mais claro."
}
```

Campos principais

- `language`: `typescript`, `javascript`, `python` ou `php`
- `context`: opcional
- `prompt_version`: opcional
- `model`: opcional

POST `/api/v1/review/stream`

Executa o mesmo review, mas em SSE.

Request

Usa o mesmo payload do endpoint `/api/v1/review`.

Eventos SSE

Os eventos emitidos são:

- `started`
- `step`
- `result`
- `error`
- `done`

Exemplo de sequência

```
{
  "event": "started",
  "data": {
    "execution_id": "uuid",
    "cache_hit": false
  }
},
{
  "event": "step",
  "data": {
    "node_name": "language_router",
    "kind": "system",
    "status": "success",
    "duration_ms": 8
  }
},
{
  "event": "result",
  "data": {
    "output": {
      "overall_quality": "good",
      "score": 9,
      "issues": [],
      "positives": [
        "Codigo simpl"
      ]
    }
  }
},
{
  "event": "done",
  "data": {}
}
```

POST `/api/v1/review/pull-request`

Executa review de Pull Request no GitHub com Jira opcional.

Request

```
{
  "github_pull_request_url": "https://github.com/org/repo/pull/123",
  "jira_issue_key": "CPJ-123",
  "base_branch": "main",
  "prompt_version": 1,
  "model": "openai/gpt-4o-mini"
}
```

Response

```
{
  "verdict": "needs_attention",
}
```

```

"score": 78,
"summary": "O PR esta consistente, mas possui alertas relevantes de segurança e padrão.",
"pull_request": {
  "owner": "org",
  "repo": "repo",
  "number": 123,
  "title": "Ajusta regras de cobrança",
  "base_branch": "main",
  "head_sha": "abc123",
  "changed_files": 6
},
"jira": {
  "issue_key": "CPJ-123",
  "summary": "Ajustar fluxo de renegociação",
  "criteria count": 3,
  "evaluated": true
},
"sections": {
  "code_standard": {
    "status": "warning",
    "findings": []
  },
  "jira_criteria": {
    "status": "passed",
    "criteria": []
  },
  "project_consistency": {
    "status": "passed",
    "findings": []
  },
  "security": {
    "status": "warning",
    "findings": []
  }
},
"positives": [
  "Boa separação por módulo"
],
"recommendations": [
  "Revisar validações de entrada sensível."
]

```

POST /api/v1/compliance

Compara tarefa e implementação.

Request

```
[{"task_description": "Permitir renegociacao apenas para contratos ativos e registrar audit", "code": "if (contract.active) { renegotiate(contract); audit(contract.id); }", "language": "typescript", "prompt_version": 1, "model": "deepseek/deepseek-v4-flash"}]
```

Response

```
[{"compliant": true, "compliance_score": 95, "covered_requirements": ["Valida contrato ativo antes da renegociacao."], "missing_requirements": [], "partial_requirements": [], "verdict": "Aderente."}]
```

POST `/api/v1/document`

Gera documentacao tecnica ou operacional.

Request

```
[{"code": "export function charge(amount: number) { return amount > 0; }", "language": "typescript", "doc_type": "technical", "prompt_version": 1, "model": "openai/gpt-4o-mini"}]
```

Response

```
[{"doc_type": "technical", "title": "Servico de cobranca", "description": "Valida se uma cobranca possui valor positivo.", "inputs": [{"name": "amount"}]}
```

```
{
  "type": "number",
  "description": "Valor da cobrança."
},
{
  "name": "return",
  "type": "boolean",
  "description": "Indica se o valor é positivo."
},
{
  "side_effects": [],
  "usage_example": "charge(100)",
  "notes": null
}
```

POST `/api/v1/tests`

Gera casos e arquivo de testes.

Request

```
{
  "code": "export function charge(amount: number) { return amount > 0; }",
  "language": "typescript",
  "test_framework": "vitest",
  "prompt_version": 1,
  "model": "deepseek/deepseek-v4-flash"
}
```

Response

```
{
  "framework": "vitest",
  "test_file": "import { expect, it } from 'vitest';\nimport { charge } from './charge';\n",
  "test_cases": [
    {
      "name": "retorna true para valor positivo",
      "type": "happy_path",
      "description": "Valida a regra principal."
    }
  ],
  "coverage_hints": [
    "Adicionar teste para amount <= 0 quando houver regra de erro."
  ]
}
```


POST `/api/v1/tests/pull-request`

Gera testes com base nas alteracoes de um Pull Request.

Request

```
{
  "github_pull_request_url": "https://github.com/org/repo/pull/123",
  "base_branch": "main",
  "test_framework": "vitest",
  "prompt_version": 1,
  "model": "openai/gpt-4o-mini"
}
```

Response

Usa o mesmo schema de resposta do endpoint `/api/v1/tests`.

POST `/api/v1/batch`

Executa varios itens em sequencia.

Request

```
{
  "continue_on_error": true,
  "notify": false,
  "items": [
    {
      "flow_type": "review",
      "payload": {
        "code": "function sum(a, b) { return a + b; }",
        "language": "javascript"
      }
    },
    {
      "flow_type": "tests",
      "payload": {
        "code": "export function charge(amount: number) { return amount > 0; }",
        "language": "typescript",
        "test_framework": "vitest"
      }
    }
  ]
}
```

Response

```
[{"batch_id": "uuid-do-batch", "status": "success", "results": [{"index": 0, "flow_type": "review", "execution_id": "execution-review-1", "status": "success", "cache_hit": false, "output": {"overall_quality": "good", "score": 9, "issues": [], "positives": ["Codigo simples e legivel."]}, "summary": "Sem problemas relevantes"}, {"error_message": null}], [{"index": 1, "flow_type": "tests", "execution_id": "execution-tests-1", "status": "success", "cache_hit": true, "output": {"framework": "vitest", "test_file": "import { expect, it } from 'vitest';\n...", "test_cases": [], "coverage_hints": []}, {"error_message": null}]]
```

Endpoints de historico e analytics

GET **/api/v1/history**

Lista execucoes recentes.

Query params

- `limit`
- `cursor`
- `flow_type`
- `status`
- `model`
- `from`
- `to`
- `cache_hit`

Exemplo

```
GET /api/v1/history?limit=20&flow_type=review&status=success
```

Response resumida

```
{
  "items": [
    {
      "id": "uuid",
      "type": "review",
      "status": "success",
      "timestamp": "2026-05-26T10:30:00-03:00",
      "duration_ms": 1240,
      "cache_hit": false,
      "source_execution_id": null,
      "telemetry": null,
      "steps": [
        {
          "node_name": "language router",
          "kind": "system",
          "status": "success",
          "duration_ms": 8
        }
      ]
    }
  ],
  "page": {
    "limit": 20,
    "next_cursor": null
  }
}
```

GET `/api/v1/history/:id`

Retorna o detalhamento completo da execucao, incluindo:

- `input_payload`
- `output_payload`
- `error_message`
- `steps` completos
- `telemetry`

GET `/api/v1/analytics/usage`

Agrega execucoes e consumo.

Query params

- `flow_type`
- `model`
- `from`
- `to`

Response resumida

```
{
  "totals": {
    "executions": 12,
    "successful": 10,
    "failed": 2,
    "cache_hits": 3,
    "prompt_tokens": 14000,
    "completion_tokens": 6200,
    "total_tokens": 20200,
    "cache_read_tokens": 500,
    "cost_total_usd": 0.024,
    "cost_input_usd": 0.009,
    "cost_output_usd": 0.015,
    "average_duration_ms": 980
  },
  "by day": [],
  "by flow": []
}
```

```
"by_model": []  
]
```

Endpoints de prompts

GET `/api/v1/prompts`

Lista versoes por fluxo. Requer query `flow_type`.

Exemplo

```
GET /api/v1/prompts?flow_type=review
```

GET `/api/v1/prompts/:flowType/active`

Busca a versao ativa de um fluxo.

GET `/api/v1/prompts/:flowType/:version`

Busca uma versao especifica.

POST `/api/v1/prompts`

Cria nova versao.

Exemplo

```
{  
  "flow_type": "document",  
  "name": "Document v2",  
  "blocks": [  
    {  
      "block_key": "agent",  
      "system_prompt": "Voce gera documentacao tecnica usando o contexto {{language context  
    }  
  ]  
}
```

POST `/api/v1/prompts/:flowType/:version/activate`

Ativa uma versao existente.

Endpoints de modelos

GET `/api/v1/models`

Lista modelos cadastrados.

GET `/api/v1/models/default`

Retorna o modelo padrao global.

POST `/api/v1/models`

Request

```
{  
  "name": "anthropic/claude-3.5-haiku"  
}
```

PATCH `/api/v1/models/:id`

Request

```
{  
  "is_default": true  
}
```

DELETE `/api/v1/models/:id`

Remove um modelo nao padrao.

Healthcheck e Swagger

GET `/health`

Retorna o status operacional da API.

GET `/docs`

Abre a documentacao interativa Swagger/OpenAPI.

Relacao entre endpoints e persistencia

Nem todo endpoint apenas responde e termina. Alguns tambem influenciam o que vai para o historico e para analytics:

- `review`, `compliance`, `document`, `tests` e `pull-request review` podem gerar execucoes persistidas;
- `batch` cria um resumo de lote e pode acionar varios subfluxos persistidos;
- `history` e `analytics` leem a base persistida;
- `prompts` e `models` alteram governanca em runtime.

Onde validar manualmente

Para teste manual rapido, os melhores pontos de entrada sao:

- `requests/cpj-cobranca-api.http`
- `GET /docs`
- `GET /health`

Relacao com os proximos capitulos

Depois deste capitulo, o proximo passo natural e `07-dados-cache-telemetria.md`, que mostra como essas respostas, steps, custos, prompts e modelos ficam guardados no banco.

Dados, Cache e Telemetria

Objetivo deste capítulo

Este capítulo explica como a aplicação persiste execuções, steps, telemetria, prompts, modelos e resumos de batch.

O objetivo é mostrar que a solução não trata o uso de IA como algo efêmero. Cada execução importante deixa rastros que podem ser consultados, agregados e auditados depois.

Visão geral da persistência

O projeto usa PostgreSQL com Prisma e concentra a modelagem principal em:

- `Execution`
- `ExecutionStep`
- `ExecutionTelemetry`
- `PromptVersion`
- `RegisteredModel`
- `GlobalModelSettings`
- `BatchExecution`

Essa estrutura atende quatro necessidades centrais do caso:

- histórico rastreável;
- governança de prompts;
- governança de modelos;
- medição de custo e uso.

Diagrama de entidades

```

erDiagram
    Execution ||--o{ ExecutionStep : "gera"
    Execution ||--o{ ExecutionTelemetry : "possui"
    Execution ||--o{ Execution : "origina cache hit"
    RegisteredModel ||--o{ GlobalModelSettings : "pode ser default"

    Execution {
        string id
        string flowtype
        string status
        json inputPayload
        json outputPayload
        int durationMs
        string requestHash
        boolean cacheHit
        string sourceExecutionId
        string errorMessage
        datetime createdAt
    }

    ExecutionStep {
        string id
        string executionId
        string nodeName
        string kind
        string status
        json inputPayload
        json outputPayload
        int durationMs
        string errorMessage
        datetime createdAt
    }

    ExecutionTelemetry {
        string id
        string executionId
        string provider
        string modelRequested
        string modelUsed
        string openrouterGenerationId
        int promptTokens
        int completionTokens
        int totalTokens
        decimal costUsd
        decimal inputCostUsd
        decimal outputCostUsd
        int cacheReadTokens
    }

    PromptVersion {
        string id
        string flowtype
        int version

```

```
    string name
    string blockKey
    string systemPrompt
    boolean isActive
}
RegisteredModel {
    string id
    string name
    boolean isActive
}
GlobalModelSettings {
    string id
    string defaultModelId
}
BatchExecution {
    string id
    string status
    int itemCount
    int successCount
    int failedCount
    int durationMs
}
```

Execucoes de fluxo

Tabela **Execution**

Execution é o registro central de uma execucao.

Campos principais:

- **flowType**: qual fluxo rodou;
- **status**: **pending**, **success** ou **failed**;
- **inputPayload**: payload original;
- **outputPayload**: resposta final quando houver sucesso;
- **durationMs**: duracao total;
- **requestHash**: hash usado para cache;
- **cacheHit**: indica reaproveitamento;
- **sourceExecutionId**: aponta para a execucao fonte em caso de cache hit;

- `errorMessage`: mensagem final de falha, quando existir.

Fluxos registrados

O enum `ExecutionFlowType` cobre:

- `review`
- `compliance`
- `document`
- `tests`
- `batch`
- `pull_request_review`

Isso deixa claro que a persistencia cobre tanto os fluxos obrigatorios quanto alguns diferenciais relevantes.

Steps de execucao

Tabela `ExecutionStep`

`ExecutionStep` registra o caminho interno de cada execucao.

Campos principais:

- `nodeName`
- `kind`
- `status`
- `inputPayload`
- `outputPayload`
- `durationMs`
- `errorMessage`

Tipos de step

O enum `ExecutionStepKind` inclui:

- `system`
- `tool`
- `prompt`
- `llm`
- `parser`
- `persistence`
- `webhook`
- `cache`

Na prática, isso permite diferenciar:

- uma etapa de orquestração;
- uma tool determinística;
- uma chamada a agente LLM;
- uma etapa de webhook;
- um cache hit ou cache lookup.

Telemetria de uso e custo

Tabela `ExecutionTelemetry`

`ExecutionTelemetry` guarda metadados de consumo do provedor LLM.

Campos principais:

- `provider`
- `modelRequested`
- `modelUsed`
- `openrouterGenerationId`
- `promptTokens`
- `completionTokens`

- `totalTokens`
- `costUsd`
- `inputCostUsd`
- `outputCostUsd`
- `cacheReadTokens`

Essa estrutura permite responder perguntas como:

- quanto um fluxo consumiu;
- qual modelo foi usado de fato;
- quanto custou uma execucao;
- quanto do uso veio de leitura de cache do provider.

Como cache funciona

O cache e baseado em hash do payload de entrada.

Logica geral

1. o engine calcula `requestHash`;
2. procura uma execucao anterior com mesmo hash e status `success`;
3. se encontrar, cria uma nova execucao marcada com `cacheHit=true`;
4. essa nova execucao aponta para a original em `sourceExecutionId`.

Por que criar nova execucao em cache hit

Essa escolha e importante porque preserva rastreabilidade de uso real.

Sem isso, haveria duas perdas:

- a API devolveria uma resposta sem registrar que aquela chamada aconteceu;
- analytics e historico subestimariam o uso do sistema.

Com o modelo atual, existe reaproveitamento de resultado sem perder trilha operacional.

Relacao pai-filho no cache

A auto-relacao em **Execution** permite ligar:

- uma execucao fonte;
- varias execucoes filhas reaproveitando aquele resultado.

Isso e particularmente util em cenarios de batch, demonstracao repetida ou uso intensivo do mesmo input.

Historico exposto pela API

O historico publico nao retorna o schema Prisma cru. Ele passa por mapeamento para contratos HTTP mais amigaveis.

Exemplos de transformacao:

- **flowType** -> **type**
- **createdAt** -> **timestamp**
- **durationMs** -> **duration_ms**
- **cacheHit** -> **cache_hit**
- **sourceExecutionId** -> **source_execution_id**

O mesmo acontece com telemetria e steps, para manter consistencia com os contratos HTTP da API.

Filtros e leitura operacional

GET /api/v1/history permite filtrar por:

- **flow_type**
- **status**
- **model**

- `from`
- `to`
- `cache_hit`

Isso so funciona bem porque a modelagem persistida foi pensada desde o inicio com esses cenarios de consulta em mente.

Analytics de uso

O endpoint `GET /api/v1/analytics/usage` agrega dados a partir das execucoes e da telemetria relacionada.

Os agrupamentos principais sao:

- totais gerais;
- por dia;
- por fluxo;
- por modelo.

Os campos agregados incluem:

- execucoes;
- sucessos e falhas;
- cache hits;
- tokens;
- custos;
- duracao media.

Prompts versionados no banco

Tabela `PromptVersion`

Em vez de tratar prompt como texto solto em arquivo apenas, a aplicacao pode resolver versoes persistidas por:

- `flowType`
- `version`
- `blockKey`

Cada linha representa um bloco de prompt, nao um documento unico inteiro.

Isso permite que um fluxo como `review` tenha varios blocos independentes:

- `naming_clarity`
- `error_handling`
- `resource_leak`
- `complexity`
- `security`
- `aggregator`

Ativacao

O campo `isActive` define qual versao esta ativa para aquele fluxo em runtime.

Catalogo de modelos

Tabela `RegisteredModel`

Guarda o catalogo de modelos aceitos pela aplicacao.

Campos principais:

- `name`
- `isActive`

Tabela `GlobalModelSettings`

Guarda a referencia do modelo padrao global.

Esse desenho separa duas responsabilidades:

- quais modelos existem e podem ser usados;
- qual deles e o default atual.

Batch persistido

Tabela `BatchExecution`

Guarda resumo operacional de lotes executados.

Campos principais:

- `status`
- `itemCount`
- `successCount`
- `failedCount`
- `durationMs`

Esse registro nao substitui as execucoes individuais dos subfluxos. Ele atua como visao consolidada do lote.

Tipos de status na base

Status de execucao

`ExecutionStatus`:

- `pending`
- `success`
- `failed`

Status de batch

`BatchStatus`:

- `success`
- `partial`
- `failed`

Isso permite representar tanto fluxo individual quanto consolidacao de lote sem forçar um unico enum para cenarios diferentes.

Como os dados sustentam a governanca do case

Essa modelagem da base sustenta varias qualidades importantes da entrega:

- auditoria de como uma resposta foi produzida;
- comparacao entre execucoes;
- medicao de custo do uso de IA;
- ativacao controlada de prompts e modelos;
- reuso por cache sem perder rastreabilidade.

Limites assumidos no modelo atual

O modelo atual foi desenhado para o escopo do case e assume alguns limites:

- nao ha multi-tenant;
- nao ha tabela dedicada de usuarios;
- nao ha fila de jobs persistida;
- `BatchExecution` resume o lote, mas nao modela subitens como entidade propria;
- prompts continuam tendo fallback local em alguns cenarios.

Esses limites nao prejudicam a proposta da entrega, mas deixam claro onde uma versao futura poderia evoluir.

Relacao com os proximos capitulos

Depois deste capitulo, os proximos documentos aprofundam a camada de governanca que usa esses dados:

- [08-prompts-modelos-governanca.md](#)
- [09-painel-web-admin.md](#)
- [11-deploy-operacao.md](#)

Prompts, Modelos e Governança

Objetivo deste capítulo

Este capítulo explica como a aplicação governa o comportamento dos fluxos de IA sem depender exclusivamente de código-fonte hardcoded.

O foco está em dois pilares:

- versionamento e ativação de prompts;
- catálogo e resolução de modelos em runtime.

Visão geral da governança

A governança do projeto foi desenhada para separar duas perguntas:

- **como o agente deve se comportar?**
- **qual modelo deve executar esse comportamento?**

Para responder essas perguntas, a aplicação usa:

- `PromptVersion`, para armazenar blocos de prompt por fluxo;
- `RegisteredModel`, para catalogar modelos aceitos;
- `GlobalModelSettings`, para definir o modelo padrão global;
- `prompt_version` e `model`, para overrides por request.

Por que essa camada existe

Sem uma camada de governança, qualquer ajuste de comportamento exigiria:

- editar arquivo de prompt local;
- rebuild da aplicação;

- novo deploy.

Com a estrutura atual, a API consegue:

- cadastrar novas versoes de prompt;
- ativar uma versao por fluxo;
- trocar o modelo padrao global;
- sobrescrever prompt e modelo em chamadas individuais.

Isso aproxima a entrega de uma operacao real e melhora bastante a avaliacao do case, porque mostra controle fino sobre a camada de IA.

Versionamento de prompts

Estrutura conceitual

Prompts nao sao tratados como um documento unico por fluxo. Eles sao divididos em blocos menores, o que deixa o comportamento mais modular.

Cada registro de prompt tem:

- `flowType`
- `version`
- `name`
- `blockKey`
- `systemPrompt`
- `isActive`

Blocos por fluxo

Review

O fluxo `review` exige os blocos:

- `naming_clarity`

- `error_handling`
- `resource_leak`
- `complexity`
- `security`
- `aggregator`

Compliance, document e tests

Esses fluxos exigem apenas:

- `agent`

Pull request review

O fluxo `pull_request_review` exige:

- `code_standard`
- `jira_criteria`
- `project_consistency`
- `security`
- `aggregator`

Ativacao de versoes

Para cada fluxo, a aplicacao usa uma versao ativa por padrao. Essa ativacao e controlada pelo endpoint:

```
POST /api/v1/prompts/:flowtype/:version/activate
```

Quando uma nova versao vira ativa:

- requests futuras passam a usar esse conjunto;
- nao e necessario rebuild;

- o comportamento do fluxo muda de forma rastreável.

Override por request

Mesmo com uma versão ativa global por fluxo, a API aceita `prompt_version` em requests individuais.

Isso permite:

- comparar duas versões sem trocar o padrão global;
- testar comportamento novo em ambiente controlado;
- validar ajustes antes de promover uma versão.

Resolver de prompts em runtime

A resolução de prompts é feita pela camada `PromptRuntimeResolver`.

Ela é responsável por:

- carregar a versão ativa quando `prompt_version` não é informado;
- carregar a versão específica quando houver override;
- validar se todos os blocos obrigatórios daquele fluxo existem;
- montar um runtime prompt set compatível com o fluxo.

Fallback legado

O projeto ainda possui um fallback local por meio de `LegacyPromptRuntimeResolver`.

Isso significa que, na ausência de repositório persistido configurado, o sistema consegue continuar operando com catálogos locais de prompt.

Esse comportamento foi uma escolha pragmática para:

- manter testes simples;

- não bloquear ambientes sem banco configurado;
- preservar backward compatibility durante a evolução da base.

Seed inicial de prompts

O `prisma/seed.ts` cria o conjunto inicial de prompts quando a tabela ainda não possui dados.

O seed inclui:

- `Review v1`
- `Compliance v1`
- `Document v1`
- `Tests v1`
- `Pull Request Review v1`

Isso garante que o projeto sobe com um conjunto funcional de comportamento sem exigir cadastro manual logo no primeiro boot.

Catalogo de modelos

Tabela `RegisteredModel`

O catalogo de modelos define quais nomes podem ser usados pela API.

Cada modelo possui:

- `id`
- `name`
- `isActive`

Isso evita que qualquer request informe nomes arbitrários ou inconsistentes.

Tabela `GlobalModelSettings`

Essa tabela guarda o modelo padrao global da aplicacao.

Com isso, a escolha do modelo default deixa de ser apenas uma env var e passa a ser parte da governanca persistida do sistema.

Modelo padrao global

Quando um endpoint nao recebe o campo `model`, a aplicacao tenta usar:

1. o modelo padrao global persistido;
2. o fallback operacional definido por `OPENROUTER_DEFAULT_MODEL`, quando necessario.

Esse desenho equilibra dois objetivos:

- governanca persistida e editavel por API;
- resiliencia em ambientes onde a tabela ainda nao esteja pronta.

Seed inicial de modelos

O seed inicial cadastra:

- `openai/gpt-4o-mini`
- `deepseek/deepseek-v4-flash`

E define como padrao inicial:

- `openai/gpt-4o-mini`

Override de modelo por request

Assim como acontece com prompts, requests individuais podem informar `model`.

Esse override so funciona se:

- o modelo estiver cadastrado;

- o modelo estiver ativo.

Com isso, a API permite experimentação controlada sem abrir mão de governança.

Endpoints de governança

Prompts

- `GET /api/v1/prompts`
- `GET /api/v1/prompts/:flowType/active`
- `GET /api/v1/prompts/:flowType/:version`
- `POST /api/v1/prompts`
- `POST /api/v1/prompts/:flowType/:version/activate`

Modelos

- `GET /api/v1/models`
- `GET /api/v1/models/default`
- `POST /api/v1/models`
- `PATCH /api/v1/models/:id`
- `DELETE /api/v1/models/:id`

Relação com os fluxos

Essa camada não é isolada do restante da aplicação. Ela participa diretamente da execução dos fluxos:

- services resolvem modelo em runtime;
- engines resolvem prompt set antes de invocar o grafo;
- PR review e review tradicional usam blocos diferentes;
- o painel web usa esses endpoints para operação administrativa.

Benefícios técnicos da governança atual

Os principais ganhos desse desenho são:

- menor acoplamento entre comportamento de IA e deploy;
- possibilidade de experimentação controlada;
- rastreabilidade de mudanças de prompt;
- controle sobre quais modelos podem ser usados;
- base clara para auditoria e administração.

Limites assumidos

O modelo atual ainda tem alguns limites conscientes:

- não existe histórico de quem ativou uma versão;
- não há aprovação em duas etapas para mudança de prompt ou modelo;
- prompts não possuem ambiente separado por tenant ou workspace;
- não existe avaliação automática de performance de prompt por versão.

Mesmo assim, para o escopo do case, a governança entregue já mostra maturidade acima do mínimo exigido.

Relação com os próximos capítulos

Depois deste capítulo, a leitura natural é:

- [09-painel-web-admin.md](#), para ver essa governança operada via interface;
- [10-como-rodar.md](#), para subir tudo localmente;
- [13-extensibilidade.md](#), para entender como adicionar novos blocos, fluxos e modelos.

Painel Web Admin

Objetivo deste capítulo

Este capítulo descreve o painel web localizado em `apps/web`, que funciona como uma camada visual de operacao sobre a API.

O painel nao substitui a API nem concentra a logica principal dos fluxos. Ele atua como console tecnico para:

- visualizar metricas;
- consultar historico;
- administrar prompts e modelos;
- executar fluxos de forma guiada;
- validar status da API e acesso ao Swagger.

Papel do painel no contexto do case

O case nao exigia um frontend administrativo, mas essa interface ajuda muito em avaliacao e demonstracao.

Ela torna mais facil:

- explorar os recursos sem depender apenas de JSON bruto;
- inspecionar dados persistidos;
- provar que analytics, historico, prompts e modelos realmente funcionam;
- operar fluxos principais com menos atrito.

Stack do painel

O painel foi construido com:

- Next.js 16

- React 19
- Ant Design 6
- Ant Design Charts

Essa escolha segue a ideia de uma interface operacional, densa e objetiva, em vez de uma camada visual decorativa ou de marketing.

Integracao com a API

Toda a informacao do painel vem da API. Ele usa `NEXT_PUBLIC_API_BASE_URL` para definir o endpoint base em runtime.

Isso preserva uma separacao clara:

- a API continua sendo a fonte de verdade;
- o painel e apenas cliente da API.

Navegacao principal

O shell principal expoe as seguintes rotas:

- `/` - Dashboard
- `/history` - Historico
- `/prompts` - Prompts
- `/models` - Modelos
- `/execute` - Executar fluxos
- `/status` - Status/API Docs

Dashboard

O dashboard e a visao inicial do painel. Ele se apoia em `GET /api/v1/analytics/usage`.

Informacoes exibidas

- total de execucoes;
- custo total;
- taxa de cache hit;
- taxa de sucesso e falha;
- tempo medio;
- ranking por fluxo;
- ranking por modelo;
- pulso diario de tokens.

Objetivo operacional

O dashboard transforma a telemetria persistida em uma leitura rapida da saude do sistema. E a tela mais util para perceber padroes de uso e custo sem abrir execucoes individuais.

Historico

A tela de historico consome:

- `GET /api/v1/history`
- `GET /api/v1/history/:id`

Recursos principais

- filtro por fluxo;
- filtro por status;
- paginacao via cursor;
- abertura de drawer com detalhe da execucao;
- exibicao de telemetria;
- timeline de steps;
- visualizacao de payloads de entrada e saida.

Valor tecnico

Essa pagina mostra com clareza que a persistencia nao e apenas conceitual. O avaliador consegue ver:

- execucoes reais;
- steps reais;
- custos e tokens;
- payloads associados.

Prompts

A tela de prompts opera a camada de governanca de comportamento.

Recursos principais

- escolha do fluxo;
- carregamento da versao ativa;
- visualizacao de versoes existentes;
- criacao de nova versao com blocos por fluxo;
- ativacao de versao.

Diferenca por fluxo

A interface se adapta ao tipo de fluxo:

- fluxos simples usam apenas **agent**;
- **review** expoe todos os blocos especialistas e aggregator;
- **pull_request_review** expoe os blocos especificos desse fluxo.

Modelos

A tela de modelos opera o catalogo permitido da API.

Recursos principais

- cadastro de novo modelo;
- listagem de modelos;
- ativacao/desativacao;
- definicao de modelo padrao;
- exclusao de modelo nao padrao.

Valor para o case

Essa tela ajuda a demonstrar que a escolha do modelo nao esta enterrada em env ou no codigo do runner. Existe de fato uma camada administrativa por cima.

Executar fluxos

A tela **Executar fluxos** e uma camada guiada para testes manuais.

Abas disponiveis

- Review
- Compliance
- Document
- Tests
- PR Review
- PR Tests
- Batch

Objetivo

Essa pagina permite executar os fluxos mais importantes sem montar requests manualmente fora da aplicacao.

Ela e especialmente util para:

- demonstracao do case;
- validacao manual rapida;

- exploracao dos contratos por quem ainda nao viu o `.http`.

Status/API Docs

A tela de status tem foco em conectividade e operacao.

Recursos

- consulta ao `GET /health`;
- exibicao do estado operacional;
- link para Swagger;
- link para o JSON OpenAPI.

Essa pagina funciona como ponto rapido para confirmar se a API esta disponivel e para abrir a documentacao interativa.

Cliente HTTP compartilhado

O painel centraliza chamadas HTTP em uma camada de cliente comum.

Isso ajuda a:

- manter endpoints concentrados em um lugar;
- padronizar serializacao de query string;
- manter tipos alinhados entre frontend e API.

Experiencia esperada do avaliador

Com o painel ativo, um avaliador tecnico consegue:

1. abrir o dashboard e ver o resumo operacional;
2. consultar historico e detalhes de execucao;
3. alterar prompts ou modelos;

4. disparar fluxos manualmente;
5. abrir Swagger e cruzar contratos.

Isso melhora bastante a experiencia de entendimento do projeto.

Limites assumidos no painel atual

O painel foi desenhado como console tecnico e assume alguns limites:

- nao ha autenticacao;
- nao ha controle de permissao por perfil;
- nao existe editor rico de prompt;
- o dashboard usa leitura agregada simples, nao drill-down analitico profundo;
- o execute page nao expoe todos os campos possiveis de todos os endpoints.

Esses limites sao coerentes com o escopo do case e nao diminuem o valor operacional da interface entregue.

Relacao com os proximos capitulos

Depois deste capitulo, o passo natural e [10-como-rodar.md](#), para subir API, banco e painel juntos em ambiente local.

Como Rodar

Objetivo deste capítulo

Este capítulo mostra como executar o projeto localmente, com e sem Docker, e como validar rapidamente que a aplicação subiu corretamente.

Pre-requisitos

Para rodar o projeto localmente, o ambiente esperado inclui:

- Node.js 22 ou superior;
- npm;
- Docker e Docker Compose;
- PostgreSQL local, caso opte por rodar sem container para o banco.

Instalar dependencias

```
npm install
```

O `postinstall` do projeto executa `prisma generate`, então o Prisma Client fica preparado logo na instalação.

Variaveis de ambiente

O ponto de partida é `.env.example`.

```
cp .env.example .env
```

Variaveis mais importantes

- `DATABASE_URL`

- `OPENROUTER_API_KEY`
- `OPENROUTER_DEFAULT_MODEL`
- `EXTERNAL_RETRY_ATTEMPTS`
- `EXTERNAL_RETRY_BASE_DELAY_MS`
- `NEXT_PUBLIC_API_BASE_URL`

Variaveis opcionais de integracao

- `GITHUB_TOKEN`
- `JIRA_BASE_URL`
- `JIRA_EMAIL`
- `JIRA_API_TOKEN`
- `LANGSMITH_TRACING`
- `LANGSMITH_API_KEY`
- `LANGSMITH_PROJECT`
- `WEBHOOK_CALLBACK_URL`

Rodando em desenvolvimento local

1. Subir PostgreSQL

Se quiser usar apenas o banco em container:

```
docker compose up -d postgres
```

2. Ajustar `.env`

Em ambiente local sem a API em container, a `DATABASE_URL` padrao deve apontar para `localhost`.

3. Rodar migrations e seed

```
npx prisma migrate dev --name init
npx prisma db seed
```

Ou, se preferir os scripts do projeto:

```
npm run prisma:migrate
npm run prisma:seed
```

4. Iniciar a API

```
npm run dev
```

5. Iniciar o painel web

Em outro terminal:

```
npm run dev:web
```

URLs locais esperadas

Com tudo no ar:

- API: <http://localhost:3000>
- Health: <http://localhost:3000/health>
- Swagger: <http://localhost:3000/docs>
- Painel: <http://localhost:3001>

Rodando com Docker Compose

Para subir API, banco e painel juntos:

```
cp .env.example .env
docker compose up --build -d
```

Observacoes importantes

- em Docker, a API usa `postgres` como host de banco;
- a API executa `prisma migrate deploy` e `prisma db seed` antes de subir;
- o painel sobe apontando para `http://localhost:3000` por padrao.

Logs uteis

API

```
docker compose logs -f api
```

Painel web

```
docker compose logs -f web
```

Banco

```
docker compose logs -f postgres
```

Validacao rapida de subida

Healthcheck

```
curl http://localhost:3000/health
```

Resposta esperada:

```
{  
  "status": "ok"  
}
```

Swagger

Abrir:

```
http://localhost:3000/docs
```

Painel

Abrir:

```
http://localhost:3001
```

Validacao manual dos fluxos

O caminho mais rapido para validar os endpoints e:

- abrir `requests/cpj-cobranca-api.http`;
- executar os exemplos principais;
- conferir o historico em `/api/v1/history`;
- abrir o painel e validar dashboard, prompts, modelos e execute page.

Ordem recomendada de verificacao

1. `GET /health`
2. `GET /docs`
3. `POST /api/v1/review`
4. `GET /api/v1/history`
5. painel em `http://localhost:3001`

Rodando somente a web

Se a API ja estiver no ar em outro endereco, basta ajustar:

```
NEXT_PUBLIC_API_BASE_URL=http://localhost:3000
```

E depois subir a web:

```
npm run dev:web
```

Rodando build de producao localmente

API

```
npm run build
npm start
```

Web

```
npm run build:web
npm run start --workspace apps/web
```

Problemas comuns logo na subida

- `OPENROUTER_API_KEY` vazia: fluxos com LLM nao executam corretamente;
- `DATABASE_URL` errada: migrations e API falham ao conectar;
- banco ainda nao pronto: a API pode falhar em boot se a dependencia nao estiver acessivel;
- `NEXT_PUBLIC_API_BASE_URL` incorreta: o painel sobe, mas nao consegue carregar dados;
- `GITHUB_TOKEN` ausente: PR review e PR tests podem falhar em repositorios que exigem autenticacao.

Comandos de desenvolvimento mais usados

```
npm run dev
npm run dev:web
npm test
npm run typecheck
npm run lint
npm run build
```



```
npm run build:web
```

Relacao com os proximos capitulos

Depois deste capitulo, a leitura natural e:

- [11-deploy-operacao.md](#)
- [12-testes-validacao.md](#)
- [14-troubleshooting-faq.md](#)

Deploy e Operacao

Objetivo deste capitulo

Este capitulo descreve como o projeto esta preparado para deploy e operacao em producao, com foco no fluxo atual baseado em Docker Compose, GitHub Actions, VPS e Nginx.

Visao geral do deploy

O deploy de producao foi desenhado para funcionar assim:

1. push na branch `main`;
2. GitHub Actions roda CI;
3. workflow gera `.env` de producao;
4. workflow envia configuracao para a VPS;
5. script remoto atualiza o codigo e sobe os containers;
6. healthchecks validam API e web.

```
Flowchart LR
  Dev["Push na main"] --> GH["GitHub Actions"]
  GH --> CI["Lint + build API + build web"]
  CI --> ENV["Gera .env.production"]
  ENV --> VPS["Copia .env para VPS"]
  VPS --> SCRIPT["scripts/deploy.sh"]
  SCRIPT --> COMPOSE["docker compose + overrides de prod"]
  COMPOSE --> CHECK["healthchecks API e web"]
```

Workflow GitHub Actions

O workflow principal esta em:

```
github/workflows/deploy.yml
```

Gatilhos

- `push` para `main`
- `workflow_dispatch`

Etapas de CI

Antes do deploy, o pipeline executa:

- `npm ci`
- `npm run lint`
- `npm run build`
- `npm run build:web`

Isso ajuda a impedir deploy de código quebrado logo na etapa de integração.

Geracao do `.env` de producao

O workflow monta um `.env.production` temporario com variaveis como:

- `OPENROUTER_API_KEY`
- `OPENROUTER_DEFAULT_MODEL`
- `EXTERNAL_RETRY_ATTEMPTS`
- `EXTERNAL_RETRY_BASE_DELAY_MS`
- `GITHUB_TOKEN`
- `JIRA_BASE_URL`
- `JIRA_EMAIL`
- `JIRA_API_TOKEN`
- `LANGSMITH_TRACING`
- `LANGSMITH_API_KEY`
- `WEBHOOK_CALLBACK_URL`
- `API_PORT_MAP`
- `WEB_PORT_MAP`

Esse arquivo é enviado para a VPS e copiado como `.env` do projeto.

Docker Compose em produção

O deploy usa:

- `docker-compose.yml`
- `docker-compose.prod.yml`

O `compose base` define a estrutura geral dos serviços. O `override de produção` ajusta principalmente:

- `secrets` e `envs` reais;
- portas bindadas em `127.0.0.1`;
- configuração de banco em produção;
- `NEXT_PUBLIC_API_BASE_URL` para o domínio esperado.

Serviços principais

postgres

Banco relacional do projeto.

api

Serviço Fastify com Prisma, fluxos de IA, Swagger e endpoints administrativos.

web

Painel Next.js consumindo a API já publicada.

Script remoto de deploy

O orquestrador remoto está em:

```
scripts/deploy.sh
```

Responsabilidades do script

- entrar no diretorio de deploy;
- fazer `git fetch`, `checkout` e `pull`;
- instalar configs de Nginx se necessario;
- recarregar Nginx;
- executar `docker compose up -d --build --remove-orphans`;
- esperar o banco;
- validar healthchecks da API e da web.

Healthchecks de producao

O script usa:

- API: `http://127.0.0.1:3020/docs`
- Web: `http://127.0.0.1:3021`

Isso prova que os servicos subiram localmente na VPS antes da exposicao via Nginx.

Nginx

O deploy assume arquivos de configuracao em:

```
deploy/nginx
```

No primeiro deploy, o script copia configs para:

- `/etc/nginx/sites-available`
- `/etc/nginx/sites-enabled`

Depois valida com `nginx -t` e recarrega o servico.

Segredos e variáveis esperadas

Secrets do GitHub Actions

Os principais secrets/vars usados no deploy são:

- `VPS_SSH_KEY`
- `VPS_HOST`
- `VPS_PORT`
- `VPS_USER`
- `OPENROUTER_API_KEY`
- `OPENROUTER_DEFAULT_MODEL`
- `EXTERNAL_RETRY_ATTEMPTS`
- `EXTERNAL_RETRY_BASE_DELAY_MS`
- `GH_PAT`
- `JIRA_BASE_URL`
- `JIRA_EMAIL`
- `JIRA_API_TOKEN`
- `LANGSMITH_TRACING`
- `LANGSMITH_API_KEY`
- `WEBHOOK_CALLBACK_URL`

Variáveis de infraestrutura

- `DEPLOY_PATH`
- `REPO_URL`

Comportamento esperado do deploy

Quando o fluxo está correto:

1. o workflow valida build;

2. o servidor recebe a nova `.env`;
3. o repositório remoto é atualizado na VPS;
4. os containers são rebuildados;
5. healthchecks ficam verdes;
6. o ambiente publicado passa a servir a nova versão.

Operação no dia a dia

As operações mais comuns em produção tendem a ser:

- acompanhar logs dos containers;
- validar healthcheck;
- revisar erro de integração externa;
- confirmar se prompts/modelos no banco batem com o esperado;
- acompanhar custo e tokens via histórico e analytics.

Logs úteis em ambiente remoto

No host da VPS, comandos úteis incluem:

```
docker compose -f docker-compose.yml -f docker-compose.prod.yml logs -f api
docker compose -f docker-compose.yml -f docker-compose.prod.yml logs -f web
docker compose -f docker-compose.yml -f docker-compose.prod.yml logs -f postgres
```

Pontos de atenção operacionais

- `OPENROUTER_API_KEY` ausente ou inválida interrompe os fluxos com LLM;
- `GH_PAT` ausente pode afetar PR review e PR tests;
- `LANGSMITH_TRACING=true` sem chave útil não ajuda na observabilidade;
- `WEBHOOK_CALLBACK_URL` com erro não quebra o fluxo principal, mas gera step de falha no histórico;
- valores ruins de retry podem aumentar latência em caso de erro externo.

Recuperacao e diagnostico

Quando algo falha em producao, a ordem mais util de diagnostico costuma ser:

1. conferir execucao do workflow;
2. validar `.env` gerado;
3. revisar logs do `api`;
4. testar `GET /health` e `GET /docs`;
5. revisar conectividade com banco e OpenRouter;
6. validar Nginx e portas locais.

Limites assumidos na operacao atual

O deploy atual foi desenhado para o case e, por isso, assume:

- uma VPS unica;
- deploy por Docker Compose;
- ausencia de orquestrador como Kubernetes;
- observabilidade operacional relativamente simples;
- rollout direto, sem estrategia blue/green.

Esses limites sao coerentes com o escopo da entrega e deixam a operacao mais facil de entender.

Relacao com os proximos capitulos

Depois deste capitulo, a leitura natural e:

- `12-testes-validacao.md`
- `14-troubleshooting-faq.md`

Testes e Validacao

Objetivo deste capitulo

Este capitulo mostra como validar tecnicamente a entrega: testes automatizados, comandos de qualidade e validacoes manuais mais relevantes.

Filosofia de validacao do case

Como este projeto foi construido para um case tecnico, a validacao precisa provar tres coisas:

- a API sobe;
- os fluxos principais respondem corretamente;
- a base tecnica e consistente o suficiente para evolucao.

Por isso, a estrategia combina:

- testes automatizados;
- verificacoes de build e lint;
- validacao manual de endpoints e painel.

Suite automatizada do backend

O backend usa Vitest como runner principal.

Cobertura funcional esperada

A suite cobre, entre outros pontos:

- rotas principais;
- contracts Zod;
- historico;
- analytics;

- prompts;
- modelos;
- review;
- compliance;
- document;
- tests;
- batch;
- PR review;
- PR tests;
- retry;
- docker e workflow em pontos criticos.

Suite automatizada da web

O frontend em `apps/web` tambem possui testes com Vitest e Testing Library.

Esses testes validam paginas como:

- dashboard;
- history;
- prompts;
- models;
- execute;
- status;
- cliente HTTP compartilhado.

Comandos principais de validacao

Backend

```
npm test
npm run typecheck
npm run lint
npm run build
```

Frontend

```
npm run build:web
npm run test:web
```

O que cada comando prova

`npm test`

Prova que a suite principal do backend segue verde.

`npm run typecheck`

Prova que o TypeScript compila semanticamente sem erros.

`npm run lint`

Prova consistencia estatica e higiene de codigo nas pastas alvo.

`npm run build`

Prova que a API empacota corretamente para producao.

`npm run build:web`

Prova que o painel compila e gera build de producao.

`npm run test:web`

Prova que a camada de interface principal continua funcional.

Validacao manual recomendada

Mesmo com testes automatizados, o case ganha muito quando passa por uma rodada manual simples.

Passo 1

Validar:

```
GET /health
```

Passo 2

Abrir:

```
GET /docs
```

Passo 3

Executar pelo menos uma request de cada fluxo principal:

- `review`
- `compliance`
- `document`
- `tests`

Passo 4

Executar:

- `batch`
- `review/pull-request`
- `tests/pull-request`

quando as credenciais externas estiverem disponiveis.

Passo 5

Conferir:

- `GET /api/v1/history`
- `GET /api/v1/analytics/usage`

Passo 6

Abrir o painel e validar:

- dashboard;
- history;
- prompts;
- models;
- execute;
- status.

Validacao via arquivo `.http`

O arquivo:

```
requests/cpj-cobranca-api.http
```

e a referencia mais pratica para demonstracao manual dos endpoints.

Ele concentra exemplos prontos para uso durante:

- desenvolvimento;
- depuracao;
- demonstracao;
- avaliacao do case.

Critérios de aceite técnicos

Uma leitura objetiva dos criterios de aceite para a entrega atual seria:

1. a API sobe localmente;
2. o banco conecta e persiste execucoes;
3. os quatro fluxos obrigatorios funcionam;
4. o historico pode ser consultado;
5. a documentacao OpenAPI esta disponivel;
6. o projeto roda em Docker;
7. o painel web consegue consumir a API;
8. os diferenciais mais importantes estao operacionais.

O que esta sendo efetivamente provado

Ao combinar testes, build e validacao manual, a entrega demonstra:

- corretude contratual;
- funcionamento dos endpoints;
- integridade da base de codigo;
- consistencia de build;
- prontidao para avaliacao tecnica.

Testes versus integracoes externas

Nem tudo precisa depender de chamadas reais a OpenRouter, GitHub ou Jira para ser validado com confianca.

A estrategia do projeto privilegia:

- testes de contratos e rotas;
- isolamento de dependencias;
- validacao estrutural da aplicacao;
- demonstracao manual quando integracoes reais estiverem disponiveis.

Isso é adequado ao contexto de case, onde a clareza do desenho conta tanto quanto a presença de todos os ambientes externos.

Riscos residuais

Mesmo com a suite atual, alguns riscos continuam existindo:

- variação de qualidade do LLM em execução real;
- instabilidade de credenciais externas;
- comportamento de custo/token dependente do provedor;
- falhas de rede em PR review, PR tests ou webhook.

Esses pontos, no entanto, ficam bem delimitados e visíveis pela arquitetura e pela telemetria do projeto.

Relação com os próximos capítulos

Depois deste capítulo, os capítulos mais úteis para aprofundar a manutenção do projeto são:

- [13-extensibilidade.md](#)
- [14-troubleshooting-faq.md](#)

Extensibilidade

Objetivo deste capítulo

Este capítulo explica como evoluir a solução sem quebrar o desenho atual. O foco é mostrar como adicionar novos fluxos, linguagens, agentes, tools, prompts e modelos com o menor atrito possível.

Princípio de extensibilidade da base

O projeto foi estruturado para crescer por composição de módulos, e não por acúmulo de lógica em um único ponto central.

Na prática, isso significa que evoluções costumam seguir um padrão claro:

- criar contrato;
- criar módulo ou expandir módulo existente;
- registrar rota;
- plugar persistência quando necessário;
- incluir prompt e governança;
- adicionar testes.

Como adicionar um novo fluxo

O caminho natural para um novo fluxo seria:

1. criar schema Zod em `src/shared/contracts`;
2. criar módulo em `src/modules/<novo-fluxo>`;
3. adicionar `routes`, `controllers`, `services`, `engines` e `graphs` conforme a complexidade;
4. registrar a rota em `src/app.ts`;
5. decidir se o fluxo deve persistir execução;

6. criar documentacao OpenAPI;
7. adicionar exemplos no `.http`;
8. adicionar testes.

Como adicionar uma nova linguagem ao review

O fluxo `review` foi desenhado para suportar evolucao por linguagem.

Para incluir uma nova linguagem, o caminho geral seria:

1. atualizar o schema de linguagens suportadas;
2. criar um novo `language profile`;
3. criar um novo grafo especifico da linguagem;
4. atualizar o `LanguageRouter`;
5. registrar o novo grafo no `ReviewFlowGraph`;
6. cobrir com testes.

Esse desenho evita condicoes gigantes espalhadas em varios lugares.

Como adicionar um novo agente especialista

No review, especialistas sao blocos bem definidos.

Para criar um novo especialista:

1. definir o objetivo da analise;
2. criar a classe do agente;
3. adicionar bloco de prompt correspondente;
4. incluir o agente no grafo de linguagem;
5. decidir como o aggregator deve consumir a nova saida;
6. atualizar contratos, se necessario;
7. adicionar testes.

Como adicionar uma nova tool determinística

As tools são uma boa porta de extensão quando o comportamento pode ser expresso por heurística objetiva.

O caminho geral seria:

1. criar ou expandir o runner determinístico do fluxo;
2. devolver achados em formato compatível com o contexto do agente;
3. registrar o step no grafo;
4. ajustar prompts se o agente passar a consumir esse novo sinal.

Como adicionar um novo bloco de prompt

Quando um fluxo precisa de governança mais fina, um novo bloco pode ser uma boa evolução.

O processo natural seria:

1. incluir o novo `PromptBlockKey`;
2. ajustar schema e validações da camada de prompts;
3. atualizar seed, se fizer sentido;
4. ajustar o resolver de runtime;
5. adaptar o fluxo que vai consumir esse bloco;
6. refletir a mudança no painel de prompts.

Como adicionar um novo modelo

Se o objetivo for apenas experimentar um novo modelo já suportado pelo OpenRouter, o caminho mais simples e administrativo:

1. cadastrar em `/api/v1/models`;
2. ativar ou definir como padrão;
3. testar via override por request ou como default global.

Se a evolucao exigir outro provider, o impacto e maior e tende a envolver:

- camada de factory do chat model;
- telemetria;
- retry;
- shape de custo e metadata.

Como evoluir PR review

O fluxo `pull_request_review` ja esta desenhado para crescer por secoes.

Alguns exemplos de evolucao natural:

- novo agente de performance;
- novo agente de observabilidade;
- leitura de mais fontes de contexto;
- ampliacao da carga de padroes do projeto;
- novas secoes no aggregator final.

Como evoluir PR tests

O fluxo de testes por PR pode crescer em especial nos pontos:

- heurísticas de extracao de funcoes criticas;
- suporte mais forte a classes e metodos;
- enriquecimento do contexto do diff;
- estrategias especificas por framework.

Como evoluir historico e analytics

A modelagem atual ja oferece boa base para:

- novos filtros;

- novos agrupamentos;
- dashboards mais ricos;
- comparacao entre modelos;
- comparacao entre versoes de prompt.

Em outras palavras: a base ja esta preparada para evoluir de observacao operacional simples para analise mais profunda.

Como evoluir o painel web

O painel tambem foi separado por features, o que favorece crescimento por tela.

Evolucoes naturais incluem:

- filtros mais ricos no dashboard;
- visualizacao lado a lado de prompts;
- editor mais avancado de blocos;
- telas especificas para PR review e PR tests;
- comparador de custo por modelo.

Boas praticas para evoluir esta base

As melhores evolucoes tendem a seguir alguns principios:

- manter contratos e implementacao alinhados;
- preferir extensao modular a refatoracoes amplas desnecessarias;
- preservar rastreabilidade e steps;
- adicionar testes junto com novas capacidades;
- documentar cada novo comportamento em README, Swagger e docs.

O que nao vale a pena fazer cedo demais

Algumas evolucoes podem parecer atraentes, mas nao sao prioridade imediata para esta base:

- microservicacao precoce;
- excesso de abstracoes para todos os fluxos;
- provider-agnostic generico demais antes de necessidade real;
- fila distribuida complexa sem demanda operacional concreta.

Relacao com os proximos capitulos

Depois deste capitulo, o capitulo mais util para sustentar a manutencao do projeto no dia a dia e [14-troubleshooting-faq.md](#).

Troubleshooting e FAQ

Objetivo deste capítulo

Este capítulo reúne problemas comuns, sintomas prováveis e caminhos de diagnóstico para API, banco, painel, integrações externas e deploy.

A API não sobe

Sintomas comuns

- erro logo no boot;
- `GET /health` indisponível;
- container `api` reiniciando.

Verificações recomendadas

1. conferir `DATABASE_URL`;
2. conferir `OPENROUTER_API_KEY`;
3. validar se o banco está acessível;
4. revisar logs da API;
5. validar se migrations e seed foram aplicados.

Erro de banco de dados

Causas comuns

- host incorreto na `DATABASE_URL`;
- banco ainda não pronto;
- porta errada;
- migrations não aplicadas.

Acoes uteis

```
docker compose logs -f postgres
npx prisma migrate dev
npm run prisma:deploy
```

GET /health responde, mas fluxos falham

Isso normalmente indica que a API subiu, mas alguma integracao essencial nao esta funcional.

Verificar

- `OPENROUTER_API_KEY`
- modelo padrao global
- modelo solicitado na request
- conectividade externa
- retry e mensagens de erro no historico

Falha com OpenRouter

Causas provaveis

- chave invalida;
- limite do provider;
- modelo nao disponivel;
- telemetria externa indisponivel.

Observacoes

- o fluxo de retry pode repetir chamadas transitorias;
- telemetria adicional nao impede necessariamente a resposta principal;

- o historico pode mostrar falha em step LLM com detalhes uteis.

O modelo informado na request nao funciona

Causas provaveis

- modelo nao cadastrado;
- modelo cadastrado, mas inativo;
- typo no nome enviado.

O que validar

- `GET /api/v1/models`
- modelo padrao em `GET /api/v1/models/default`
- payload enviado no endpoint

Prompt nao muda mesmo depois de cadastrar nova versao

Causas comuns

- nova versao criada, mas nao ativada;
- request usando `prompt_version` antigo explicitamente;
- fluxo com fallback local em ambiente sem repositorio persistido ativo.

Verificar

- `GET /api/v1/prompts/:flowType/active`
- `POST /api/v1/prompts/:flowType/:version/activate`
- payload efetivo da chamada

PR review ou PR tests falham

Causas prováveis

- `GITHUB_TOKEN` ausente ou insuficiente;
- URL do PR inválida;
- repositório privado sem permissão;
- `JIRA_*` ausentes quando Jira é exigido;
- indisponibilidade de GitHub ou Jira.

Verificações úteis

- confirmar formato da URL do PR;
- revisar se `base_branch` faz sentido;
- validar se `jira_issue_key` é realmente necessário;
- checar logs e steps como `github_fetch` e `jira_fetch`.

Webhook falha

Comportamento esperado

Falha no callback de webhook não derruba a resposta principal do fluxo.

Onde aparece

- em `ExecutionStep`, como `webhook_callback` com status `failed`;
- em logs da API;
- potencialmente no histórico detalhado.

O que revisar

- `WEBHOOK_CALLBACK_URL`

- disponibilidade do endpoint externo;
- autenticação exigida no destino;
- latência e timeout.

Painel web não carrega dados

Causas comuns

- `NEXT_PUBLIC_API_BASE_URL` incorreta;
- API fora do ar;
- CORS ou rota errada;
- frontend apontando para ambiente errado.

Verificar

- abrir a tela `Status/API Docs`;
- conferir o valor de `API Base`;
- testar `GET /health` diretamente na URL configurada.

Swagger não abre

Possíveis causas

- API ainda não subiu por completo;
- erro de rota reversa via Nginx;
- problema de proxy em produção.

Validação

- testar localmente `GET /docs`;
- em produção, validar healthcheck local da API;

- revisar configuracoes de Nginx.

Analytics vazio

Causas comuns

- nenhuma execucao persistida ainda;
- fluxo rodou, mas falhou antes de gerar telemetria;
- filtros muito restritivos.

O que fazer

- executar um fluxo simples;
- consultar `GET /api/v1/history`;
- remover filtros de `flow_type`, `model`, `from` e `to`.

Historico sem detalhes esperados

Possiveis causas

- cache hit com pouca execucao nova;
- integracao sem telemetria retornada pelo provider;
- falha antes da gravacao de determinados steps.

Validacao

- abrir `GET /api/v1/history/:id`;
- comparar execucao original e execucao cache hit;
- conferir steps gravados.

Docker sobe, mas a web nao abre

Verificar

- `WEB_PORT_MAP`
- logs do container `web`
- build do Next.js
- disponibilidade da API de backend

Deploy na VPS nao conclui

Verificacoes uteis

1. revisar o workflow do GitHub Actions;
2. validar secrets de SSH;
3. revisar `scripts/deploy.sh`;
4. revisar logs dos containers;
5. validar `nginx -t` no host;
6. testar healthchecks locais `127.0.0.1:3020` e `127.0.0.1:3021`.

Retry parece aumentar muito a latencia

Causa provavel

Valores altos de tentativas e delay base podem elevar o tempo total de espera em falhas externas.

O que revisar

- `EXTERNAL_RETRY_ATTEMPTS`
- `EXTERNAL_RETRY_BASE_DELAY_MS`

FAQ rapido

Preciso de GitHub e Jira para todos os fluxos?

Nao. Eles sao relevantes principalmente para `review/pull-request` e `tests/pull-request`.

Posso rodar sem LangSmith?

Sim. O tracing e opcional.

Posso rodar sem webhook?

Sim. O callback e opcional.

Posso rodar sem painel?

Sim. A API funciona independentemente da interface web.

O case depende de Ollama?

Nao. O provedor padrao atual e OpenRouter.

Relacao com o proximo capitulo

Depois deste capitulo, o `15-glossario.md` ajuda a consolidar os principais termos tecnicos usados ao longo da documentacao.

Glossario

Objetivo deste capítulo

Este glossario resume os termos técnicos e de domínio mais usados ao longo da documentação do projeto.

Termos principais

Agent

Componente orientado a LLM que recebe contexto, segue um prompt e retorna uma saída estruturada.

Aggregator

Agente responsável por consolidar as saídas de outras etapas ou especialistas em uma resposta final única.

Analytics

Camada que agrega execuções e telemetria para gerar visão operacional por dia, por fluxo e por modelo.

Batch

Fluxo que executa vários itens de **review**, **compliance**, **document** e **tests** em sequência em uma única request.

Cache hit

Situação em que uma execução reutiliza o resultado de outra chamada anterior com o mesmo hash de payload.

Code standards

Padroes de projeto usados no review de Pull Request para avaliar aderencia do diff a regras ou convencoes locais.

Compliance

Fluxo que compara tarefa e codigo para avaliar aderencia funcional.

Controller

Camada HTTP que valida input, chama o service correto e devolve a resposta da API.

Deterministic tools

Heurísticas e análises previsíveis que rodam sem LLM e complementam os fluxos.

Document

Fluxo que gera documentacao tecnica ou operacional a partir de codigo.

Engine

Camada operacional do fluxo. Coordena cache, persistencia, telemetria, webhook e chamada do grafo principal.

Execution

Registro persistido de uma execucao de fluxo.

ExecutionStep

Registro persistido de uma etapa intermediaria de execucao.

ExecutionTelemetry

Registro persistido de tokens, custos, provider e metadados de uso do modelo.

Flow

Capacidade funcional da API, como **review**, **compliance**, **document**, **tests** ou **batch**.

FlowType

Tipo logico de fluxo usado em governanca de prompts e persistencia.

Graph

Orquestracao de nodes e transicoes que define como um fluxo de IA se comporta.

Healthcheck

Endpoint simples usado para validar se a API esta operacional.

History

Camada de consulta das execucoes persistidas, incluindo steps e telemetria.

LangChain

Biblioteca usada para structured output, mensagens e integracao com o modelo.

LangGraph

Biblioteca usada para modelar os fluxos como grafos explicitos de execucao.

LangSmith

Ferramenta opcional de tracing para fluxos de IA.

Model catalog

Catalogo persistido de modelos permitidos pela API.

Model override

Substituicao pontual do modelo padrao global em uma request especifica.

OpenAPI

Especificacao de contrato HTTP publicada pela API e usada pelo Swagger UI.

OpenRouter

Provedor LLM utilizado como gateway para modelos e telemetria associada.

Panel / Painel admin

Interface web administrativa em `apps/web` que consome a API.

PR review

Fluxo de review aplicado a um Pull Request do GitHub, com Jira opcional.

PR tests

Fluxo que gera testes unitarios a partir das alteracoes de um Pull Request.

Prompt block

Bloco individual de prompt dentro de uma versao de fluxo, como `agent`, `security` ou `aggregator`.

Prompt version

Versao persistida de um conjunto de prompts de um fluxo.

Prompt override

Uso do campo `prompt_version` para forçar uma versao especifica em uma request.

Repository

Camada responsavel por ler ou gravar dados persistidos.

Retry com backoff

Estrategia de repeticao de chamadas externas em falhas transitorias, com atraso progressivo entre tentativas.

Review

Fluxo de revisao automatizada de codigo, com especialistas por criterio.

Service

Camada de aplicacao que intermedia controller e engine, expondo o fluxo para a interface HTTP.

SSE

Server-Sent Events. Mecanismo usado para stream do endpoint `/api/v1/review/stream`.

Step recorder

Interface usada pelos grafos para registrar etapas no historico quando houver persistencia disponivel.

Structured output

Resposta do LLM validada contra schema estruturado, e nao texto livre sem contrato.

Supported language

Conjunto de linguagens aceitas pelos fluxos de codigo:

- `typescript`
- `javascript`
- `python`
- `php`

Tests

Fluxo que gera testes unitarios a partir de codigo informado.

Webhook callback

POST opcional enviado pela API ao final de certos fluxos, sem substituir a resposta HTTP principal.